ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ,
ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ
ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Εκτίμηση Επικινδυνότητας Δασικών Πυρκαγιών με Τεχνικές Βαθιάς Μάθησης και Εικόνες που έχουν ληφθεί από UAV

Διπλωματική Εργασία

Ηλίας Αργυράκης

Επιβλέπων Καθηγητής: Εμμανουήλ Ψαράκης

ΠΑΤΡΑ, ΙΟΥΛΙΟΣ, 2025

Ευχαριστίες

Με το πέρας της διπλωματικής εργασίας αυτής, τελειώνει και η προπτυχιακή, φοιτητική μου ζωή. Θα ήθελα περιληπτικά να ευχαριστήσω όλους όσους με βοήθησαν στο ταξίδι μου ετούτο.

Τους Καθηγητές μου και κυρίως τον Επιβλέποντα Καθηγητή μου Εμμανουήλ Ψαράκη, που μπόρεσε να αξιοποιήσει τις γνώσεις μου στην επιλογή του θέματος της εργασίας αυτής. Η καθοδήγηση του υπήρξε καθοριστική στην μόρφωση μου.

Έπειτα θα ήθελα να ευχαριστήσω όλους τους φίλους μου, τον Ιωσήφ και τον Πέλεκαν που με βοήθησαν στην επιλογή του τμήματος φοίτησης μου, οι συζητήσεις με τους οποίους συνέβαλαν στην ομαλή περάτωση των σπουδών μου. Τον Αχιλλέα, Βασίλη, Χάρη, Πλάτωνα και Φίλιππο, όπου με φιλοξένησαν σε αυτόν τον τόπο και έκαναν την καθημερινότητα μου πιο ευχάριστη και παραγωγική.

Τέλος θα ήθελα να ευχαριστήσω την Αδαμαντία και τον Δήμο για τις πολύτιμες αναμνήσεις που μου προσέφεραν αυτά τα χρόνια, όπως και τους γονείς μου για τη διαχρονική τους στήριξη και πίστη στις δυνατότητες μου.

Σε όλους τους αναφερόμενους και μη, ένα μεγάλο «ευχαριστώ» για αυτό το υπέροχο κεφάλαιο της ζωής μου.

Περίληψη

Η παρούσα διπλωματική εργασία παρουσιάζει την ανάπτυξη ενός πρωτότυπου συστήματος χαρτογράφησης επικινδυνότητας δασικών πυρκαγιών με αποκλειστική χρήση εικόνων, τόσο δορυφορικών όσο και ληφθεισών από UAV.

Αρχικά, συγκροτήθηκε προκαταρκτικό σετ δορυφορικών εικόνων από τη συλλογή Google Earth, το οποίο αξιοποιήθηκε για τον σχεδιασμό και την πρώτη εκπαίδευση συνελικτικών νευρωνικών δικτύων. Στη συνέχεια, δημιουργήθηκε ένα εξειδικευμένο dataset UAV μέσω πτήσεων drone, με σχολαστική ετικετοποίηση των βασικών κλάσεων (έδαφος, θάμνοι, δέντρα, δρόμοι, κτίρια και δίκτυα υψηλής τάσης). Το semantic segmentation υλοποιήθηκε σε νευρωνικό δίκτυο με U-Net αρχιτεκτονική, ενώ ειδικές τεχνικές μετα-επεξεργασίας μάσκας βασισμένες στην κατωφλίωση και φίλτρο μεσαίου (thresholding, median filtering) διασφάλισαν την ποιότητα των ετικετών.

Τα πειραματικά αποτελέσματα κατέδειξαν υψηλή ακρίβεια, ικανοποιητικό μέσο (mean) IoU και στιβαρές επιδόσεις στις πιο κρίσιμες κατηγορίες. Επιπλέον, παρουσιάζεται η διαδικασία ανάθεσης βαρών κινδύνου στους εντοπισμένους τύπους βιομάζας για την παραγωγή τελικών “risk maps”. Η εργασία ολοκληρώνεται με συζήτηση των προκλήσεων ενσωμάτωσης σε πραγματικό χρόνο, καθώς και προτάσεις για διεύρυνση του dataset, χρήση τρισδιάστατων δεδομένων και πλήρη πεδία εφαρμογής.

Abstract

This thesis presents the development of a prototype wildfire-risk mapping system based exclusively on imagery—both satellite and UAV-acquired.

First, a preliminary set of satellite images was assembled from the Google Earth collection, which was used to design and initially train convolutional neural networks. Next, a dedicated UAV dataset was created via drone flights, with meticulous annotation of the core classes (ground, shrubs, trees, roads, buildings, and high-voltage lines). Semantic segmentation was implemented using a U-Net architecture, while specialized mask post-processing techniques (thresholding, median filtering) ensured label quality.

Experimental results demonstrated high accuracy, satisfactory mean IoU, and robust performance in the most critical categories. Furthermore, we describe the procedure for assigning risk weights to each detected biomass type in order to produce the final "risk maps." The thesis concludes with a discussion of the challenges of real-time integration, as well as recommendations for expanding the dataset, incorporating 3D data, and deploying the system in full-scale field applications.

Περιεχόμενα

Ευχαριστίες 2
Περίληψη 3
Abstract 4
Γλωσσάρι 7
ΚΕΦΑΛΑΙΟ 1 10
Εισαγωγή 10
1.1 Το πρόβλημα με τις φωτιές στην Ελλάδα 10
1.2 Τρόποι αντιμετώπισης 11
1.3 Κενά σε υποδομές 12
ΚΕΦΑΛΑΙΟ 2 13
Κίνητρα & Στόχοι 13
2.1 Ανάγκη για ολοκληρωμένο σύστημα 13
2.2 Σκοπός και Ερευνητικά Ερωτήματα 15
2.2.2 Ερευνητικά Ερωτήματα 16
2.3 Δομή της διπλωματικής 16
ΚΕΦΑΛΑΙΟ 3 17
Θεωρητικό Υπόβαθρο / Σχετική Έρευνα 17
3.1 Εκτάσεις δέντρων στην Ελλάδα 17
3.2 Ποια δέντρα είναι πιο επικίνδυνα 19
3.3 Γιατί UAV και όχι μόνο δορυφορικές εικόνες 20
3.4 Σημασιολογική Τμηματοποίηση 21
ΚΕΦΑΛΑΙΟ 4 23
Μεθοδολογία 23
4.1 Εκπαίδευση με Δορυφορικές Εικόνες 23
4.1.1 Δημιουργία Συνόλου Δεδομένων (dataset) 23
4.1.2 Ετικετοποίηση (Labeling) 24
4.1.3 Περιβάλλον Εργασίας, Επεξεργασία & Εμπλουτισμός Δεδομένων 25
4.1.4 Εκπαίδευση Νευρωνικού Δικτύου 27
4.2 Εκπαίδευση με UAV Εικόνες 31
4.2.1 Περιορισμοί & Τελικό Pipeline 31
4.2.2 Σχεδιασμός & Πτήση Drone 33

4.2.3 Δημιουργία Κλάσεων & Ετικετοποίηση UAV Dataset 34
4.2.4 Προεπεξεργασία & Augmentation 42
4.2.5 Εκπαίδευση & Βελτιστοποίηση 43
ΚΕΦΑΛΑΙΟ 5 45
Πειραματικά Αποτελέσματα 45
ΚΕΦΑΛΑΙΟ 6 55
Συμπεράσματα και Μελλοντική Εργασία 55
Βιβλιογραφία 56
Παράρτημα 60

Γλωσσάρι

Δορυφορική εικόνα

Εικόνα της Γης που λαμβάνεται από δορυφόρους σε διάφορα φάσματα με συγκεκριμένη χωρική και χρονική ανάλυση.

Fuel Model (Μοντέλο Καυσίμου)

Περιγραφή τύπων βιομάζας (π.χ. ξερά χόρτα, θάμνοι, κώνους) με χαρακτηριστικά που χρησιμοποιούνται σε μοντέλα πρόβλεψης εξάπλωσης φωτιάς (Rothermel, Scott & Burgan).

FARSITE
(Fire Area Simulator) — λογισμικό προσομοίωσης εξάπλωσης και έντασης δασικών πυρκαγιών βάσει τοπογραφίας, καυσίμων και μετεωρολογικών δεδομένων.

BehavePlus
Σύστημα μοντελοποίησης συμπεριφοράς φωτιάς που επιτρέπει την πρόβλεψη ρυθμού εξάπλωσης, έντασης και παραγωγής καυσαερίων, με βάση διάφορα σενάρια και καύσιμα.

FWI (Forest Fire Weather Index)

Δείκτης επικινδυνότητας δασικών πυρκαγιών που προκύπτει από το Καναδικό Σύστημα Αξιολόγησης Καιρικών Συνθηκών–Πυρκαγιάς (Canadian Forest Fire Weather Index System), βασισμένος σε υγρασία, άνεμο, θερμοκρασία και βροχόπτωση.

UAV (Unmanned Aerial Vehicle)

Μη επανδρωμένο ιπτάμενο όχημα (drone) που μπορεί να φέρει αισθητήρες και κάμερες για συλλογή εικόνων υψηλής ανάλυσης.

Νευρωνικό Δίκτυο (Neural Network, NN)

Μοντέλο τεχνητής νοημοσύνης εμπνευσμένο από τη λειτουργία του βιολογικού νευρικού ιστού, ικανό να "μαθαίνει" σχέσεις εισόδων–εξόδων μέσω εκπαίδευσης σε σύνολα δεδομένων.

Deep Learning

Υποκατηγορία μηχανικής μάθησης που χρησιμοποιεί "βαθιά" (πολλών επιπέδων) νευρωνικά δίκτυα για την αυτόματη εξαγωγή χαρακτηριστικών από τα δεδομένα.

Semantic Segmentation

Επεξεργασία εικόνων όπου κάθε pixel ταξινομείται σε μία από τις κλάσεις (π.χ. δασική βλάστηση, δρόμοι, κτίρια), παρέχοντας ακριβή διαχωρισμό περιοχών ενδιαφέροντος.

U-Net
Αρχιτεκτονική convolutional neural network για semantic segmentation με "encoder–decoder" διάταξη και skip-connections, σχεδιασμένη για ιατρικές εικόνες αλλά ευρέως υιοθετημένη σε γεωχωρικές εφαρμογές.

Intersection over Union (IoU)

Μέτρο αξιολόγησης του segmentation, ο λόγος της τομής (πλήθος κοινών pixels) προς την ένωση (πλήθος συνολικών pixels) μεταξύ προβλεπόμενης και πραγματικής (ground truth) μάσκας.

Ground Truth

Το σύνολο των ετικετών (labels) ή των χαρτών αναφοράς που ορίζονται "χειροκίνητα" από ειδικούς και χρησιμοποιούνται για την εκπαίδευση και αξιολόγηση μοντέλων.

Labeling (Ετικετοποίηση)

Η διαδικασία απόδοσης σωστών κατηγοριών (κλάσεων) σε εικόνες ή pixels, είτε χειροκίνητα είτε με υποβοήθηση λογισμικού, για τη δημιουργία σετ εκπαίδευσης.

Pipeline
Η ολοκληρωμένη αλληλουχία επεξεργασίας δεδομένων — από τη συλλογή εικόνων έως το τελικό segmentation και την παραγωγή χαρτών επικινδυνότητας.

Script

Το μικρό κείμενο κώδικα ή αλλιώς code segment, αυτή η δομή χρησιμοποιείται στο περιβάλλον google colab για την οργανωμένη συγγραφή κώδικα.

Accuracy (Ακρίβεια)

Το ποσοστό των σωστών προβλέψεων (πραγματικών θετικών + πραγματικών αρνητικών) ως προς το σύνολο των δειγμάτων.

Precision (Ειδικότητα)

Το ποσοστό των σωστών θετικών προβλέψεων (true positives) ως προς όλα τα δείγματα που προβλέφθηκαν θετικά.

Recall (Ανάκληση ή Ευαισθησία)

Το ποσοστό των σωστών θετικών προβλέψεων (true positives) ως προς όλα τα πραγματικά θετικά δείγματα.

F1-Score
Ο αρμονικός μέσος της Precision και της Recall, που εξισορροπεί τις δύο μετρικές.

Training / Validation / Test Set

Τα υποσύνολα δεδομένων που χρησιμοποιούνται αντίστοιχα για εκπαίδευση, παραμετροποίηση (tuning) και τελική αξιολόγηση του μοντέλου.

Data Augmentation (Εμπλουτισμός Δεδομένων)

Η τεχνική αυτόματης δημιουργίας παραλλαγών των εικόνων (π.χ. περιστροφές, flips, αλλαγή φωτεινότητας) για να αυξήσουμε την ποικιλία του σετ εκπαίδευσης.

Epoch (Εποχή)

Μία πλήρης διέλευση όλων των δειγμάτων του training set μέσα στο δίκτυο κατά τη διάρκεια της εκπαίδευσης.

ΚΕΦΑΛΑΙΟ 1

Εισαγωγή

1.1 Το πρόβλημα με τις φωτιές στην Ελλάδα

Οι δασικές πυρκαγιές στην Ελλάδα έχουν λάβει διαστάσεις εθνικής τραγωδίας. Τα τελευταία χρόνια παρατηρείται αύξηση τόσο της συχνότητας όσο και της έντασης των συμβάντων, με βασικούς παράγοντες:

- την κλιματική αλλαγή,
- την παρατεταμένη ξηρασία και
- την ανεξέλεγκτη συσσώρευση καύσιμης ύλης στα δάση.

Το 2023 καταγράφηκαν περισσότερα από 174 000 στρέμματα καμένης γης, ενώ το συνολικό οικονομικό κόστος εκτιμήθηκε σε περίπου 1,8 δισ. € [20]. Ταυτόχρονα, ο αριθμός των ανθρώπινων απωλειών κυμάνθηκε μεταξύ 20–27 νεκρών, με εκατοντάδες οικογένειες να χάνουν τη στέγη τους και να εκτοπίζονται σε προσωρινά καταφύγια [20].

Οι συνέπειες δεν περιορίζονται στον άνθρωπο. Χιλιάδες άγρια ζώα (ελάφια, αλεπούδες, αρπακτικά πτηνά) και οικόσιτα (αιγοπρόβατα, άλογα, κατοικίδια) είτε έχασαν τη ζωή τους είτε εκτοπίστηκαν σε μη βιώσιμα περιβάλλοντα [21]. Επιπλέον, η καταστροφή της βλάστησης προκάλεσε τη διάβρωση των εδαφών και τη μείωση των υδατικών πόρων, πλήττοντας την αγροτική παραγωγή και τον τουρισμό μακροπρόθεσμα [22].

Σε ό,τι αφορά τις υδρολογικές επιπτώσεις, αμέσως μετά μεγάλα κύματα καταιγίδων – όπως η “Storm Daniel” τον Σεπτέμβριο 2023 – προκάλεσαν πλημμύρες σε περιοχές με καμένη βλάστηση, ιδίως στη Θεσσαλία. Εκεί, μέσα σε λίγες ώρες έπεσαν πάνω από 500 mm βροχής, με αποτέλεσμα να θρηνήσουμε 16 νεκρούς, να γκρεμιστούν γέφυρες και δρόμοι και να καταστραφούν καλλιέργειες [23]. Ο αγροτικός τομέας υπέστη σοβαρό πλήγμα, διότι τα πλούσια σε καλλιέργειες εδάφη του κάμπου παρέμειναν για αρκετό καιρό ανθυγιεινοί βιότοποι.

1.2 Τρόποι αντιμετώπισης

Η διαχείριση των δασικών πυρκαγιών στηρίζεται σε τέσσερις αλληλοσυμπληρούμενες φάσεις: πρόληψη, έγκαιρη ανίχνευση, πρόβλεψη συμπεριφοράς και καταστολή, ενώ μετά την κατάσβεση απαιτείται ανάκαμψη και αποκατάσταση.

Προληπτικά μέτρα

Οι εργασίες καθαρισμού (sanitation thinning), η διαχείριση της βιομάζας (fuel treatments) και η κατασκευή αντιπυρικών ζωνών (firebreaks) βασίζονται στα "fuel models" του Rothermel [4] και τεκμηριώνονται από τους φωτο-οδηγούς των 13 μοντέλων καυσίμου της USDA [5].

Έγκαιρη ανίχνευση

Τα δορυφορικά συστήματα MODIS και VIIRS καλύπτουν μεγάλες εκτάσεις, αλλά παρουσιάζουν περιορισμούς χωρικής ανάλυσης και χρόνου επανάληψης [3]. Η ενσωμάτωση UAV με real-time ή off-line τεχικών επεξεργασίας εικόνας—όπως έχει εφαρμοστεί για ανίχνευση οχημάτων σε έξυπνες συγκοινωνίες [2]—επιτρέπει ανίχνευση εστιών μικρής κλίμακας.

Προβλεπτικά μοντέλα συμπεριφοράς

Το FARSITE [3] και το BehavePlus [6] επιτρέπουν την προσομοίωση της εξάπλωσης και της έντασης της φωτιάς, λαμβάνοντας υπόψη:

- την καύσιμη ύλη,
- την τοπογραφία και
- τις μετεωρολογικές μεταβλητές.

Παράλληλα, ο δείκτης κινδύνου FWI (Forest Fire Weather Index) προσφέρει συνεχείς εκτιμήσεις επικινδυνότητας βάσει καιρικών δεδομένων [8].

Καταστολή

Οι επίγειες πυροσβεστικές δυνάμεις και τα εναέρια μέσα (αεροπλάνα/ελικόπτερα) αποτελούν την πρώτη γραμμή άμυνας, αλλά συχνά καθυστερούν λόγω δυσπρόσιτου εδάφους ή χαμηλής ορατότητας.

Ανάκαμψη & αποκατάσταση

Μετά την κατάσβεση πραγματοποιούνται εργασίες ελέγχου διάβρωσης, αναδασώσεις και παρακολούθηση επιπτώσεων σε έδαφος και υδρολογία, ώστε να περιοριστεί ο κίνδυνος από επόμενα έντονα καιρικά φαινόμενα.

Η ολοκληρωμένη αντιμετώπιση απαιτεί την ενσωμάτωση όλων των παραπάνω σε ένα ενιαίο πληροφοριακό σύστημα που συνδυάζει δεδομένα από επίγειους σταθμούς, δορυφορικές παρατηρήσεις και UAV, υποστηριζόμενο από μοντέλα βαθιάς μάθησης για semantic segmentation των εστιών πυρκαγιάς.

1.3 Κενά σε υποδομές

Παρά τις εκτεταμένες προσπάθειες πρόληψης και έγκαιρης ανίχνευσης, το ελληνικό σύστημα διαχείρισης πυρκαγιών εξακολουθεί να εμφανίζει κρίσιμα κενά που αυξάνουν τον κίνδυνο και επιμηκύνουν τους χρόνους ανταπόκρισης.

Η έλλειψη επαρκούς κάλυψης radar και επίγειων αισθητήρων έχει ως αποτέλεσμα τα μόνιμα δίκτυα μετεωρολογικών σταθμών να μην καλύπτουν το σύνολο της επικράτειας ή να τοποθετούνται κυρίως σε περιοχές χαμηλής επικινδυνότητας, με συνέπεια την ανίχνευση νέων εστιών να καθυστερεί έως και οκτώ με δώδεκα ώρες [20].

Η χαμηλή χωρική (250–500 m/pixel) και χρονική (12–24 h) ανάλυση των δορυφορικών εικόνων MODIS και VIIRS δεν επαρκεί για την άμεση επέμβαση σε μικρής κλίμακας δασικές εκτάσεις [24], [25].

Ακόμη και όταν η αναγνώριση πραγματοποιηθεί έγκαιρα, οι καθυστερήσεις στην κινητοποίηση των εναέριων και επίγειων μέσων οφείλονται σε δυσπρόσιτο έδαφος ή έλλειψη πρόσβασης σε κατάλληλες υδροληψίες, με αποτέλεσμα πολύτιμοι πόροι να μην φτάνουν έγκαιρα στον τόπο της εστίας [20].

Μικρο–«case study»: Στην περιοχή του Σχίνου Κορινθίας, ένας χωματόδρομος που χρησιμοποιείται για γρήγορη πρόσβαση μπάζωσε, αναγκάζοντας τις πυροσβεστικές δυνάμεις να διανύσουν επιπλέον 5 km παράκαμψης, προκαλώντας μια καθυστέρηση, η οποία επέτρεψε στη φωτιά να διπλασιάσει την έκτασή της πριν κατασβεστεί [26].

Αυτά τα κενά υπογραμμίζουν την ανάγκη για ένα ενιαίο, αυτοματοποιημένο πληροφοριακό σύστημα, ικανό να συνδυάζει μετεωρολογικές μετρήσεις, δορυφορικά και UAV δεδομένα υψηλής ανάλυσης σε πραγματικό χρόνο με αλγορίθμους μηχανικής μάθησης για accurate semantic segmentation και γρήγορη εκτίμηση επικινδυνότητας.

ΚΕΦΑΛΑΙΟ 2

Κίνητρα & Στόχοι

2.1 Ανάγκη για ολοκληρωμένο σύστημα

2.1.1 Περιορισμοί δορυφορικών εικόνων

Η παραδοσιακή παρακολούθηση δασικών πυρκαγιών στηρίζεται σε δορυφορικές πλατφόρμες όπως Sentinel-2, που διαθέτει χωρική ανάλυση 10 m και επαναλήψεις λήψης κάθε 5–12 ημέρες. Αν και παρέχει ευρεία κάλυψη και διαχρονική παρακολούθηση, η χαμηλή λεπτομέρεια των εικόνων δεν ευνοεί την έγκαιρη ανίχνευση μικρών εστιών, ενώ η ευαισθησία στα νέφη και οι σχετικά αραιές λήψεις καθυστερούν την ανταπόκριση των υπηρεσιών.

2.1.2 Πλεονεκτήματα και όρια των UAV

Η χρήση UAV (drone) επιτρέπει λήψη εικόνων με χωρική ανάλυση της τάξης των cm–m και άμεση χρονοσειρά σε πραγματικό χρόνο, διευκολύνοντας την ανίχνευση ακόμη και πολύ μικρών εστιών. Ωστόσο, η εμβέλεια πτήσης είναι περιορισμένη, η αυτονομία των μπαταριών απαιτεί συχνές προσγειώσεις, ενώ ο χειρισμός πεδίου και οι κανονισμοί πτήσεων επιβάλλουν αυξημένη οργάνωση και ασφάλεια.

2.1.3 Προτεινόμενο pipeline

Για την αντιμετώπιση των παραπάνω περιορισμών, προτείνεται ένα σύστημα (δες Σχήμα 1) που στηρίζεται αποκλειστικά σε εικόνες. Αρχικά, συλλέγονται UAV λήψεις υψηλής ανάλυσης σε προτεραιότητας ζώνες, οι οποίες ετικετοποιούνται με πολυγωνικά masks ώστε να δημιουργηθεί ένα πλήρως σχολιασμένο σετ δεδομένων. Στη συνέχεια, οι εικόνες τροφοδοτούνται σε ένα νευρωνικό δίκτυο semantic segmentation (U-Net), το οποίο έχει εκπαιδευτεί να διαχωρίζει με ακρίβεια τα διαφορετικά είδη καύσιμης βιομάζας, τους δρόμους και τις υποδομές. Μετά την κατάτμηση (segmentation), οι μάσκες υποβάλλονται σε επεξεργασία εικόνας για την παραγωγή χαρτών επικινδυνότητας.

Σε επόμενη φάση, το σύστημα θα μπορούσε να ενσωματώσει μετεωρολογικά metadata—όπως οι δείκτες που παράγει η πλατφόρμα RiskMap του Beyond EO Center—για τη δημιουργία πιο ολιστικών, δυναμικών χαρτών κινδύνου παραδείγματα των οποίων απεικονίζοντα στο Σχήμα 2 και Σχήμα 3.

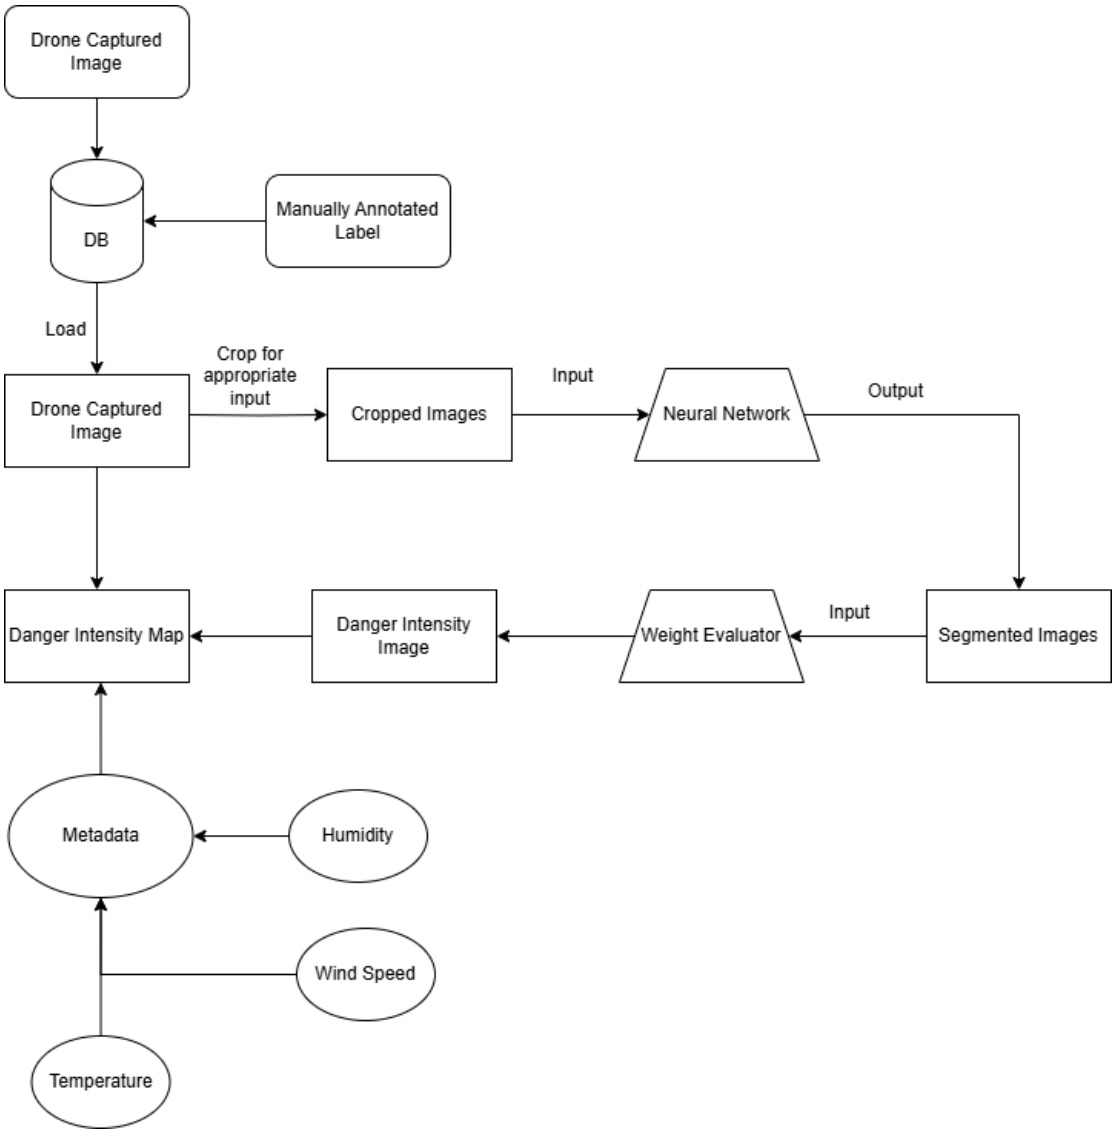

Σχήμα 1: Προτεινόμενο Pipeline.

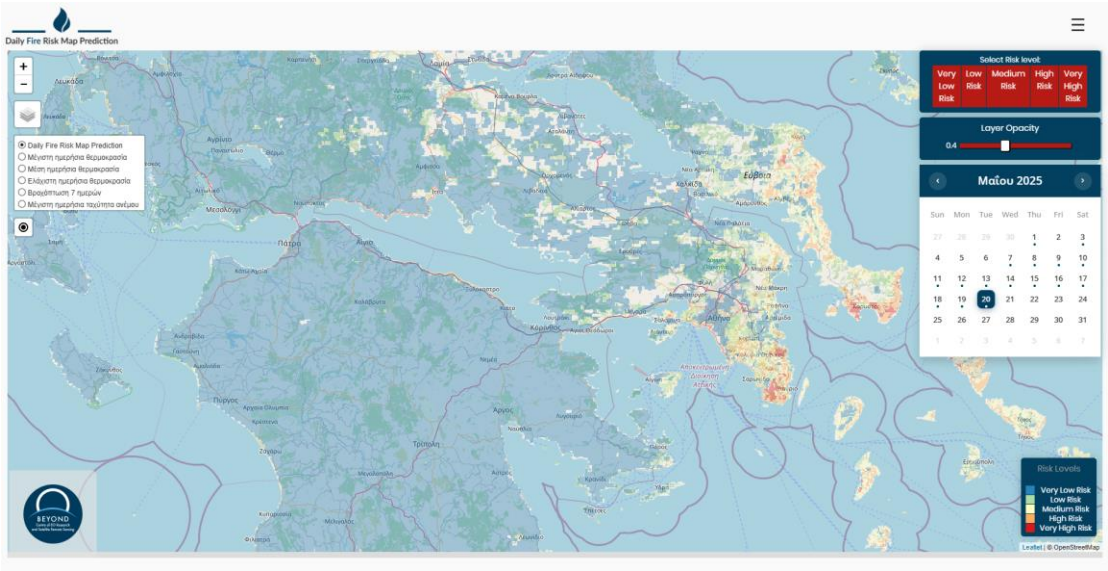

Σχήμα 2: Παράδειγμα από τον χάρτη πρόβλεψης επικινδυνότητας πυρκαγιών του Firehub.

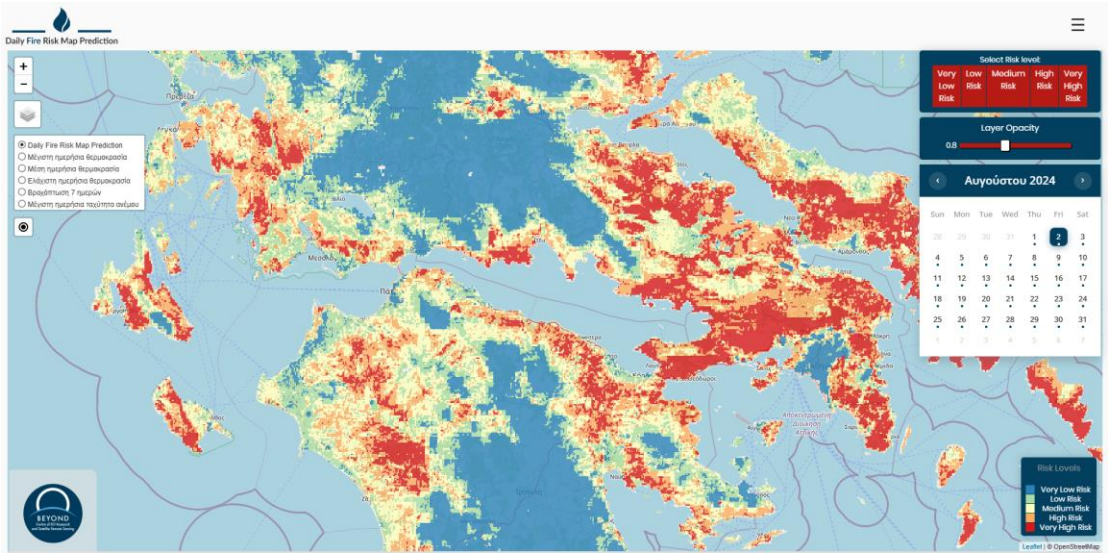

Σχήμα 3: Ένα ακόμα παράδειγμα σε μια πιο επικίνδυνη μέρα.

2.2 Σκοπός και Ερευνητικά Ερωτήματα

2.2.1 Σκοπός

Ο κύριος στόχος της εργασίας είναι να διερευνηθεί κατά πόσο είναι εφικτή η παραγωγή αξιόπιστων χαρτών επικινδυνότητας δασικών πυρκαγιών με αποκλειστική χρήση εικόνων και τεχνικών επεξεργασίας εικόνας/μηχανικής μάθησης. Η έμφαση δίνεται στην ενίσχυση της λεπτομέρειας με σκοπό την υποστήριξη στην πρόληψη, αλλά και στη διαδικασία καταστολής τέτοιων συμβάντων, όπου τα πυροσβεστικά σώματα θα μπορούσαν να συμβουλεύονται τους ολοκληρωμένους χάρτες επικινδυνότητας για να καταπολεμήσουν και να περιορίσουν τις φωτιές.

2.2.2 Ερευνητικά Ερωτήματα

Ένας τρόπος να κάνουμε πιο συγκεκριμένους τους στόχους της εργασίας αυτής, είναι θέτοντας τα παρακάτω ερωτήματα:

- Υπάρχει ικανότητα δημιουργίας χάρτη επικινδυνότητας με επαρκή ακρίβεια, συγκρίσιμο με αντίστοιχες χειροκίνητες αναφορές (ground truth);
- Ποιοι τύποι καύσιμης βιομάζας (κλάσεις εικόνων) επηρεάζουν περισσότερο τη διαμόρφωση του δείκτη κινδύνου;
- Πώς διαμορφώνει την απόδοση του μοντέλου η χωρική ανάλυση και η ποιότητα της ετικετοποίησης;
- Σε ποιο βαθμό η λεπτομέρεια των κλάσεων βελτιώνει ή επιβραδύνει τη διαδικασία segmentation και την αξιοπιστία των παραγόμενων χαρτών;

Με αυτά τα ερωτήματα οριοθετείται το θεωρητικό υπόβαθρο και καθοδηγείται η μεθοδολογική ανάπτυξη των πειραμάτων που ακολουθούν.

2.3 Δομή της διπλωματικής

Στο Κεφάλαιο 3 («Θεωρητικό Υπόβαθρο/Σχετική Έρευνα») παρουσιάζεται ανασκόπηση των δασικών εκτάσεων στην Ελλάδα, των ειδών βλάστησης και των παραμέτρων ευφλεκτότητας, καθώς και εισαγωγή στις βασικές αρχές του semantic segmentation και στην αρχιτεκτονική U-Net.

Στο Κεφάλαιο 4 («Μεθοδολογία») περιγράφεται η συνολική λύση: η συλλογή δορυφορικών και UAV εικόνων, ο σχεδιασμός και η ετικετοποίηση των σετ δεδομένων, η επιλογή κλάσεων και συνθηκών λήψης, η προεπεξεργασία και ο εμπλουτισμός των εικόνων, η υλοποίηση και ανάλυση των νευρωνικών δικτύων για segmentation, καθώς και η ανάθεση δεικτών επικινδυνότητας.

Στο Κεφάλαιο 5 («Πειραματικά Αποτελέσματα») αναφέρονται τα βασικά metrics απόδοσης (accuracy, mean IoU, F1-score) και γίνονται συγκρίσεις με το ground truth.

Στο Κεφάλαιο 6 («Συμπεράσματα και Μελλοντική Εργασία») συνοψίζονται τα κύρια ευρήματα, καταγράφονται οι περιορισμοί της μελέτης και προτείνονται βελτιώσεις για πλήρη ενσωμάτωση σε real-time περιβάλλον πεδίου.

Στο Παράρτημα υπάρχουν τα βασικά scripts και listings, ενώ στο τέλος υπάρχει η βιβλιογραφία που χρησιμοποιήθηκε.

ΚΕΦΑΛΑΙΟ 3

Θεωρητικό Υπόβαθρο / Σχετική Έρευνα

3.1 Εκτάσεις δέντρων στην Ελλάδα

Σε εθνικό επίπεδο, οι δασικές εκτάσεις καλύπτουν περίπου το 30,3 % της συνολικής εδαφικής έκτασης της χώρας το 2022, αυξημένες από 25,6 % το 1990 και 30,3 % το 2010 [27], [28]. Η θετική αυτή τάση αποδίδεται κυρίως σε προγράμματα αναδάσωσης και φυσικής αναγέννησης, παρά τις απώλειες δασικής έκτασης λόγω αστικής διάχυσης και ανεξέλεγκτης βόσκησης [27].

Οι κύριες γεωγραφικές ζώνες δασικής κάλυψης και τα επικρατούντα είδη είναι [29]:

- **Παράκτιες & ημιαγροτικές περιοχές (0–400 m):** κυριαρχούν τα κωνοφόρα *Pinus halepensis* (πεύκο Aleppo) και οι μακκίες (*Quercus coccifera*).
- **Ορεινός κορμός (400–1 200 m):** υπερισχύουν *Pinus nigra* (μαύρο πεύκο), *Fagus sylvatica* (οξιά) και *Abies cephalonica* (ελάτη)
- **Μεσογειακές φρυγανικές & μικτές πλατύφυλλες (0–800 m):** σημαντική παρουσία *Quercus ilex* (αριά) και *Castanea sativa* (καστανιά), ιδιαίτερα στην Ιόνια ζώνη και το βόρειο Αιγαίο.

Σε σύνολο δασικής έκτασης, τα κωνοφόρα αντιπροσωπεύουν περίπου το 38 %, ενώ τα πλατύφυλλα το 62 % [27].

Η κατανομή της δασικής κάλυψης και των τύπων βλάστησης αποτυπώνεται χαρακτηριστικά στον χάρτη βλάστησης της Ελλάδας που παρουσιάζεται παρακάτω (δες Σχήμα 4). Ο χάρτης αυτός απεικονίζει με χρωματική διαφοροποίηση τα κυρίαρχα είδη βλάστησης σε όλη την επικράτεια, βάσει γεωγραφικών, κλιματικών και υψομετρικών χαρακτηριστικών.

Στη βόρεια και βορειοδυτική Ελλάδα, όπως η Ήπειρος, η Μακεδονία και η Θράκη, παρατηρείται έντονη παρουσία πυκνών δασών φυλλοβόλων και μεικτών δασών, με κυρίαρχα είδη την οξιά (Fagus sylvatica), την ελάτη (Abies borisii-regis, A. cephalonica) και τη μαύρη πεύκη (Pinus nigra). Οι περιοχές αυτές χαρακτηρίζονται από υψηλό υψόμετρο και μεγαλύτερη υγρασία, ευνοώντας την ανάπτυξη πλατύφυλλων ειδών.

Στην κεντρική και νότια ηπειρωτική χώρα, κυριαρχούν οι μεσογειακοί τύποι βλάστησης, όπως μακκίες, φρυγανικές εκτάσεις και χαμηλοί θαμνώνες, καθώς και συστάδες Pinus halepensis (χαλεπίου πεύκη), κυρίως σε χαμηλά και παράκτια υψόμετρα. Οι περιοχές της Πελοποννήσου, της Αττικής, της Εύβοιας και της

Θεσσαλίας εμφανίζουν εκτεταμένες εκτάσεις με μικτές συστάδες πεύκου και πλατύφυλλων ειδών, συχνά διακεκομμένες από αγροτικές ζώνες και υποδομές.

Στις νησιωτικές περιοχές, όπως τα νησιά του Αιγαίου και η Κρήτη, η βλάστηση παρουσιάζει μεγαλύτερη ανομοιομορφία. Οι ξηροθερμικές συνθήκες ευνοούν κυρίως τη θαμνώδη βλάστηση, ωστόσο σε ημιορεινές ζώνες εμφανίζονται συστάδες κέδρων (Juniperus spp.), πλατύφυλλων δρυών (Quercus spp.) και τοπικά καστανεώνων, όπως στη Βόρεια Εύβοια και τη Σάμο. Στην Κρήτη, διακρίνονται τυπικά μεσογειακά οικοσυστήματα με έντονη παρουσία φρυγάνων, μακκίας βλάστησης και χαλεπίου πεύκης στα ανατολικά.

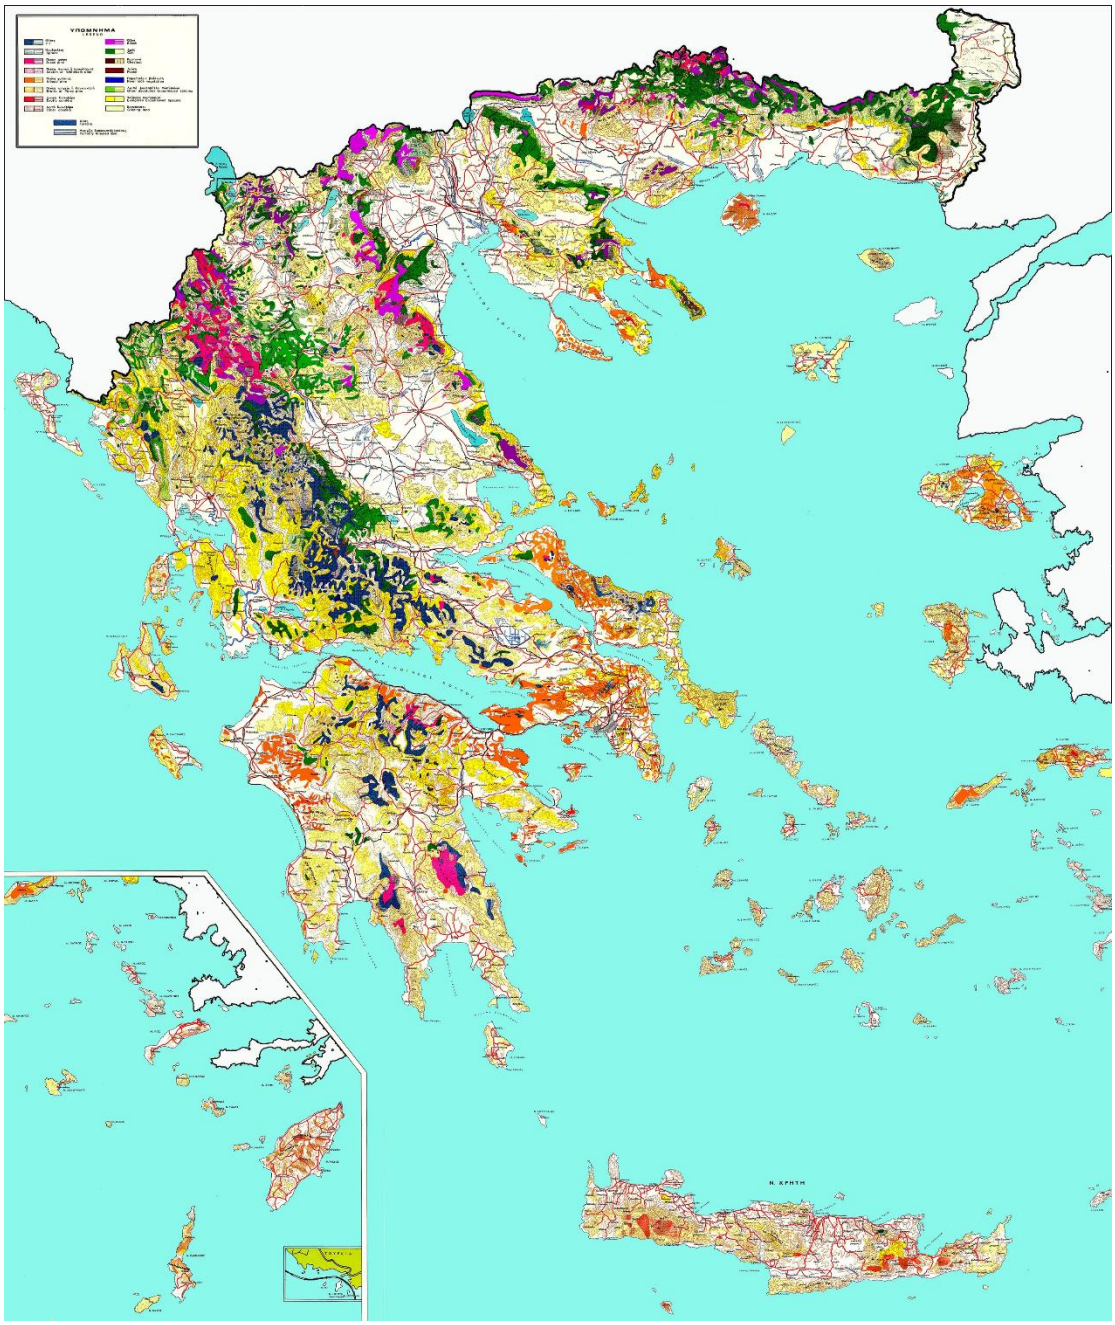

Σχήμα 4: Χάρτης που παρουσιάζει την κατανομή διαφορετικών ειδών δέντρων στην Ελλάδα.

3.2 Ποια δέντρα είναι πιο επικίνδυνα

Η ευφλεκτότητα των δέντρων καθορίζεται από μια σειρά φυσιολογικών και χημικών χαρακτηριστικών που επηρεάζουν τόσο τον χρόνο ανάφλεξης όσο και τη ραγδαία εξάπλωση της φωτιάς. Καταρχήν, η Fuel Moisture Content (FMC), δηλαδή η περιεκτικότητα σε νερό του ξύλου και των βελόνων/φύλλων, επιμηκύνει σημαντικά τον χρόνο ανάφλεξης όταν είναι υψηλή, ενώ χαμηλές τιμές FMC οδηγούν σε ταχύτερη εξάπλωση της φωτιάς [1].

Ο λόγος επιφάνειας–προς–όγκο (SA/V) και η Specific Leaf Area (SLA) αποτελούν δείκτες της εκτεθειμένης στην ατμόσφαιρα επιφάνειας ανά μονάδα μάζας, συμπερασματικά μεγαλύτερες τιμές SA/V και SLA συνεπάγονται αυξημένη πρόσβαση οξυγόνου στα καύσιμα, μειωμένο χρόνο ανάφλεξης και ταχύτερη καύση [1].

Το πάχος φύλλων και φλοιού επηρεάζει τον χρόνο ανάφλεξης (time-to-ignition) και τον ρυθμό καύσης (burning rate), γιατί παχύτερα φύλλα απαιτούν μεγαλύτερη θερμότητα για να φτάσουν στη θερμοκρασία ανάφλεξης, ενώ παχύς φλοιός επιβραδύνει την πρόοδο της φλόγας και μειώνει την ετήσια απώλεια μάζας [16].

Ο όγκος και η πυκνότητα υποστρώματος φυλλωμάτων (litter bulk density) διαμορφώνει την αεροδιαπερατότηταχαμηλή πυκνότητα σχηματίζει ανοιχτή δομή που ευνοεί τη ροή οξυγόνου, ενισχύοντας την ανάφλεξη και τη διάδοση της φωτιάς [15].

Η χημική σύσταση των φυλλών (ιδίως το ποσοστό τερπενίων και λιγνίνης) καθορίζει την ευφλεκτότητα: υψηλό περιεχόμενο τερπενίων και μη–διάστικτων υδατανθράκων επιταχύνει την ανάφλεξη και ενισχύει την έντονη καύση [16], [15].

Σε εργαστηριακές δοκιμές με «litter beds», η *Pinus pinea* απέδωσε πλήρη (100 %) επιτυχία ανάφλεξης τόσο σε σημειακή (point-ignition) όσο και σε πλευρική (lateral fire-line) δοκιμή, ενώ *Cupressus sempervirens*, *Quercus ilex*, *Juniperus thurifera* και *Quercus faginea* παρουσίασαν ποσοστά επιτυχίας κάτω του 20 % ή μηδενική ανάφλεξη [15].

Συνοψίζοντας, τα κωνοφόρα—ιδίως τα είδη του γένους *Pinus*—κατατάσσονται υψηλά στην κλίμακα επικινδυνότητας, λόγω χαμηλής FMC και αστραπιαίας διάδοσης σε ανοιχτά litter beds. Αντίθετα, κάποια πλατύφυλλα όπως η *Quercus ilex* εμφανίζουν μειωμένη επιδεκτικότητα ανάφλεξης χάρη στα παχύτερα, πλούσια σε λιγνίνη φύλλα τους, αν και διατηρούν τη φλόγα για μεγαλύτερο χρόνο (sustainability). Τα είδη της οικογένειας Cupressaceae (π.χ. *C. sempervirens*) απαιτούν περισσότερο χρόνο για την ανάφλεξη, παράγοντας όμως υψηλές θερμοκρασίες και διαρκή καύση όταν τελικά αναφλέγονται.

3.3 Γιατί UAV και όχι μόνο δορυφορικές εικόνες

Οι δορυφορικές εικόνες προσφέρουν σημαντικά πλεονεκτήματα σε επίπεδο ευρείας κάλυψης και συνεχούς χρονοσειράς, αλλά παρουσιάζουν κρίσιμα όρια για την ανίχνευση και πρόληψη μικροκλιμακών εστιών δασικών πυρκαγιών. Συγκεκριμένα:

- η Sentinel-2 παρέχει χωρική ανάλυση 10 m (ενώ ορισμένα φασματικά κανάλια φτάνουν τα 20 m ή 60 m), γεγονός που σημαίνει ότι οι περιοχές κάτω των 10 × 10 m δεν καταγράφονται λεπτομερώς [30], ενώ
- οι εικόνες MODIS διαθέτουν ακόμη χαμηλότερη ανάλυση (250 m, 500 m και 1 km), καθιστώντας ανέφικτη την έγκαιρη αναγνώριση μικρών εστιών πριν αυτές λάβουν μεγάλες διαστάσεις [31].

Σε ό,τι αφορά τη χρονική ανανέωση:

- η επαναληπτικότητα της Sentinel-2 (περίπου κάθε 5 ημέρες, λόγω των δορυφόρων 2A και 2B) δεν επαρκεί για γρήγορη αντίδραση σε επεισόδια που διαμορφώνονται μέσα σε ώρες, ενώ
- οι MODIS ολοκληρώνουν παγκόσμια κάλυψη κάθε 1–2 ημέρες, δημιουργώντας παράθυρα κατά τα οποία νέες εστίες παραμένουν αθέατες [30].

Ως αποτέλεσμα, η μη άμεση ανίχνευση μικρών εστιών οδηγεί σε καθυστερημένη κινητοποίηση των δυνάμεων καταστολής και σε αυξημένο κίνδυνο απώλειας ελεγχόμενης κατάσβεσης.

Αντιθέτως, τα UAV (drones) παρέχουν χωρική ανάλυση που μπορεί να φτάσει τα cm ήm, επιτρέποντας λεπτομερή χαρτογράφηση της καύσιμης βιομάζας και ταχεία ανίχνευση εστιών σε πραγματικό χρόνο. Η ευελιξία τους σε επίπεδο πτήσεων—στοχευμένες αποστολές πάνω από κρίσιμες ζώνες, ανεξάρτητα από νέφη ή τοπογραφικούς περιορισμούς—και η δυνατότητα επαναλαμβανόμενων πτήσεων σε σύντομη χρονική κλίμακα ενισχύουν περαιτέρω την έγκαιρη ανίχνευση [2]. Επιπλέον, το χαμηλότερο αρχικό κόστος επένδυσης και λειτουργίας σε σύγκριση με τις συνδρομητικές υπηρεσίες δορυφορικής εικόνας υψηλής ανάλυσης καθιστά τα UAV εξαιρετικό συμπλήρωμα στην παραδοσιακή δορυφορική επιτήρηση.

Παραδείγματα εφαρμογών, όπως η ανίχνευση οχημάτων σε έξυπνες συγκοινωνίες [2] και η παρακολούθηση καλλιεργειών στην ακριβείας γεωργία [17], αναδεικνύουν το εύρος των δυνατοτήτων επεξεργασίας εικόνας από drones. Συνεπώς, η χρήση εικόνων που έχουν ληφθεί από UAV, συμπληρώνει αποτελεσματικά τα κενά της δορυφορικής κάλυψης, καλύπτοντας ανάγκες επιτήρησης μικρής κλίμακας και ενισχύοντας την έγκαιρη παρέμβαση απέναντι στις δασικές πυρκαγιές.

3.4 Σημασιολογική Τμηματοποίηση

Η σημασιολογική τμηματοποίηση (semantic segmentation) στοχεύει στην κατηγοριοποίηση κάθε εικοννοστοιχείου (pixel) μίας εικόνας σε μία προκαθορισμένη κλάση, παρέχοντας έναν πυκνό χάρτη μάσκας που δείχνει ακριβώς:

- ποια σημεία ανήκουν σε δασική βλάστηση,
- ποια σε δρόμους ή ανθρωπογενείς υποδομές και
- ποια σε νεκρή οργανική ύλη.

Η ιδέα των πλήρως συνδεδεμένων συνελικτικών δικτύων (Fully Convolutional Networks (FCNs)), όπως αυτά προτάθηκαν από τους Long, Shelhamer & Darrell (2015), ήταν να αντικαταστήσει τα παραδοσιακά πλήρως συνδεδεμένα στρώματα με συνελικτικά (convolutional) ώστε το δίκτυο να παράγει έξοδο σε διαστάσεις ανάλογες της εισόδου, διατηρώντας τη χωρική πληροφορία.

Παρότι τα πρώτα FCNs μείωναν σταδιακά τις διαστάσεις μέσω pooling και έχαναν λεπτομέρεια, η αρχιτεκτονική U-Net (Ronneberger, Fischer & Brox, 2015) αντιμετώπισε το πρόβλημα αυτό με ένα συμμετρικό encoder–decoder σχήμα και «γέφυρες» (skip connections) που μεταφέρουν τις λεπτομερείς πληροφορίες από τα στάδια υποδειγματοληψίας (down-sampling) στα αντίστοιχα στάδια ανύψωσης (up-sampling). Με αυτόν τον τρόπο, κάθε επίπεδο του decoder λαμβάνει τόσο τα συμπυκνωμένα χαρακτηριστικά από τον encoder όσο και τις αρχικές, πιο υψηλής ανάλυσης λεπτομέρειες, επιτυγχάνοντας κοφτέρους διαχωρισμούς ανάμεσα σε όρια κλάσεων και βελτιώνοντας σημαντικά την ακρίβεια των περιγραμμάτων (δεςΣχήμα 5).

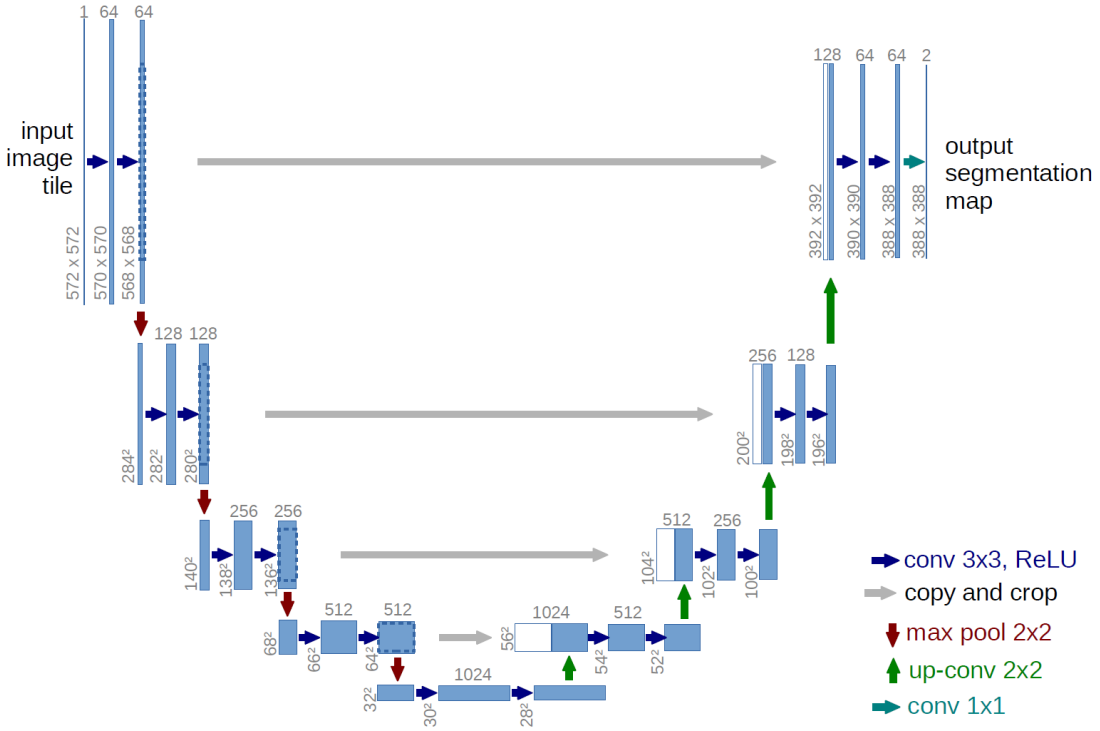

Σχήμα 5: Η αρχιτεκτονική του U-Net.

Στις γεωχωρικές εφαρμογές, το semantic segmentation επιτρέπει:

- τον χωρισμό τύπων εδαφών,
- την ακρίβεια στην καταγραφή βιομάζας (δάση, θάμνοι, χορτολιβαδικές εκτάσεις) και
- την ταχεία αναγνώριση ανθρωπογενών στοιχείων όπως δρόμοι και κτίρια,

καθιστώντας δυνατή τη δημιουργία χάρτη κινδύνου με βάση την ύπαρξη καυσίμων ή σημείων πρόσβασης.

Οι βασικοί δείκτες απόδοσης:

- Intersection over Union (IoU),
- Pixel Accuracy και
- F1-Score

μετρούν αντίστοιχα την τομή των μάσκων πρόβλεψης και ground truth, το ποσοστό σωστών pixels συνολικά και την ισορροπία ανάμεσα σε false positives και false negatives, διασφαλίζοντας ότι το μοντέλο δεν υπερτονίζει ούτε παραλείπει τις κρίσιμες κλάσεις.

Η επιλογή του U-Net στη διπλωματική αυτή εργασία βασίζεται στην αποδεδειγμένη αποτελεσματικότητά του στη χρήση, κατά τη εκπαίδευσή του, με σχετικά μικρών συνόλων δεδομένων, χάρη στις skip connections που ενισχύουν τη μάθηση χωρικών λεπτομερειών, και στην ευελιξία της να υποστηρίζει τροφοδοσία με patches ομοιόμορφου μεγέθους (π.χ. 256×256) χωρίς απώλεια συνοχής στην έξοδο. Μετά την παραγωγή της μάσκας, οι ετικέτες κάθε pixel μετατρέπονται σε δείκτη επικινδυνότητας, στάθμιση που βασίζεται στην κρισιμότητα της κλάσης και τελικά συνδυάζονται σε χάρτη που απεικονίζει τις επικίνδυνες ζώνες προς αντιμετώπιση.

ΚΕΦΑΛΑΙΟ 4

Μεθοδολογία

4.1 Εκπαίδευση με Δορυφορικές Εικόνες

4.1.1 Δημιουργία Συνόλου Δεδομένων (dataset)

Για την εκπαίδευση των μοντέλων semantic segmentation χρειάστηκε η συγκέντρωση ενός αντιπροσωπευτικού συνόλου δορυφορικών εικόνων που να καλύπτει διαφορετικές δασικές συνθήκες και να αποφεύγει εικόνες με παρεμβολές (νέφη, χιόνι, υπερβολικές αστικές ζώνες). Η διαδικασία ακολούθησε τα εξής βήματα:

- **Πηγές εικόνων**

  Χρησιμοποιήθηκαν δορυφορικές λήψεις από το Google Earth, έναν εξαιρετικά λεπτομερή χάρτη (δες Σχήμα 6). Η ανάλυση της εικόνας αντιστοιχεί σε 50m/pixel για να είναι υπολογιστικά δυνατή η εξαγωγή εικόνων για την αναπαράσταση του χώρου.

- **Επιλογή κλάσεων & υποθέσεων**
  Τα labels της ImageCollection
  GOOGLE/DYNAMICWORLD/V1περιλαμβάνουν τις ακόλουθες κλάσεις:
  - 0. Water (Νερό)
  - 1. Trees (Δέντρα)
  - 2. Grass (Γρασίδι)
  - 3. Flooded Vegetation (Πλημμυρισμένη Βλάστηση)
  - 4. Crops (Καλλιέργειες)
  - 5. Shrub (Θάμνοι)
  - 6. Built-up Area (Δομημένη Περιοχή)
  - 7. Bare Area (Γυμνός Χώρος)
  - 8. Snow & Ice (Χιόνι & Πάγος)
  - 9. Clouds (Σύννεφα)

Για την συγκεκριμένη εφαρμογή που θα συγκεντρωθούν περισσότερα δεδομένα από τις κλάσεις άμεσα σχετιζόμενες με βλάστηση, οπότε κλάσεις όπως (8) Snow & Ice και (9) Clouds δε θα έχουν ποιοτικά αποτελέσματα σε σχέση με (1) Trees, για παράδειγμα.

Για να εξασφαλιστεί η ποιότητα του dataset και η επικέντρωση σε καθαρές, θερινές συνθήκες:

1. Ελάχιστη συννεφιά < 10 % σε κάθε εικόνα (φιλτράρισμα μέσω του μεταδεδομένου CLOUDY_PIXEL_PERCENTAGE),
2. Χαμηλή εδαφική υγρασία (καλοκαιρινή περίοδος, Ιούνιος–Σεπτέμβριος),

3. Αποφυγή εικόνων με χιονισμένα τοπία ή πλημμυρισμένα εδάφη, επιλέγοντας το 30% τουλάχιστον των κλάσεων των pixel να ανήκει στην κλάση 1: Tree,
4. Τυχαία δειγματοληψία μέσω μιας Gaussian κατανομής εντός της κεντρικής ζώνης Ελλάδας (γεωγραφικά όρια Kalamata–Thessaloniki). Πολλαπλασιάζοντας τις μεταβλητές των συντεταγμένων με μια τυχαία μεταβλητή που λαμβάνει τιμές σύμφωνα με μια Gaussian κατανομή, μπορεί να καλυφθεί διαφορετικό υψόμετρο και τύποι βλάστησης.

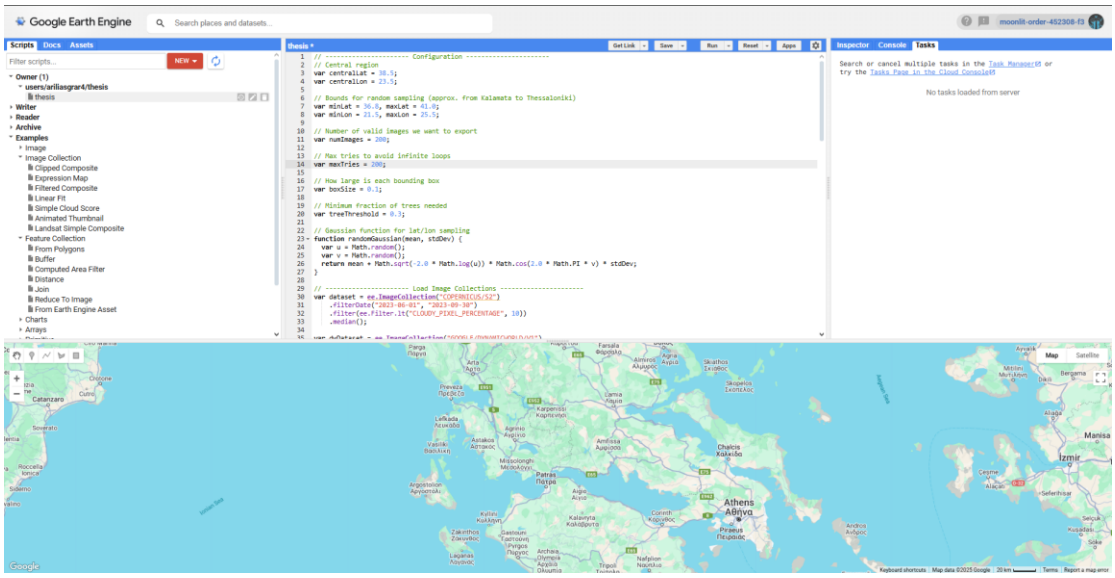

Σχήμα 6: Το περιβάλλον συγγραφής κώδικα στην υπηρεσία Google Earth.

Το πλήρες script (Listing 1) που υλοποιεί τη δειγματοληψία και την εξαγωγή των εικόνων από το Google Earth Engine παρατίθεται στο Παράρτημα Κώδικα, διασφαλίζοντας την αναπαραγωγιμότητα της διαδικασίας και την εξαγωγή ακριβώς 200 εικόνων, μεγέθους 446x446 εικονοστοιχείων (ύψος και πλάτος σε pixel), με τουλάχιστον 30 % δασική κάλυψη.

4.1.2 Ετικετοποίηση (Labeling)

Στο Google Dynamic World (DW), το labeling των Sentinel-2 εικόνων έχει ήδη γίνει με ένα προηγμένο συνελικτικό νευρωνικό δίκτυο το οποίο έχει εκπαιδευτεί σε μεγάλα σετ υψηλής ανάλυσης όπου οι ετικέτες («ground truth») προέκυψαν από χειροκίνητη σήμανση εμπειρογνωμόνων. Κάθε pixel ταξινομείται σε μία από δέκα κλάσεις (π.χ. water, trees, grass, built-up κ.λπ.), χρησιμοποιώντας χαρακτηριστικά φασματικών καναλιών ορατού και υπέρυθρου.

Ο αλγόριθμος εξάγει από κάθε Sentinel-2 εικόνα τη μάσκα ετικετών label=[0…9] για κάθε pixel με βάση τα δεδομένα του Dynamic World, ωστόσο πριν χρησιμοποιηθεί αυτή η παραγωγή στο training set, εφαρμόζεται αυστηρός ποιοτικός έλεγχος.

Συγκεκριμένα, επιλέγονται τυχαία υποσύνολα εικόνων για οπτική επιθεώρηση, ώστε να εντοπίζονται και να διαγράφονται περιοχές με επισφαλείς προβλέψεις—όπως η σύγχυση μεταξύ νερού και νεφών—ενώ, όπου χρειάζεται, γίνονται διορθώσεις μέσω κανόνων μετα-επεξεργασίας (π.χ. thresholding, majority filtering). Με τον τρόπο αυτό, διασφαλίζεται ότι οι τελικές μάσκες είναι καθαρές και αξιόπιστες, επιτρέποντας στο νευρωνικό δίκτυο να μάθει με ακρίβεια τα χαρακτηριστικά της δασικής βλάστησης και των υπόλοιπων κατηγοριών, χωρίς τον θόρυβο από λανθασμένες ετικέτες.

Ο κίνδυνος λανθασμένων ετικετών συνεπώς, είναι μεγάλος. Γι' αυτό και η χρήση ενός ετικετοποιημένου σετ δεδομένων από άνθρωπο είναι ουσιαστικής σημασίας. Σε εικόνες όμως τέτοιου υψομέτρου, η διαδικασία αυτή είναι εξαιρετικά δύσκολη και χρονοβόρα λόγω της κακής ευκρίνειας των απεικονιζόμενων εκτάσεων. Αυτό είναι προφανές ότι δεν ισχύει στις εικόνες που έχουν ληφθεί από drone, με συνέπεια η διαδικασία ετικετοποίησής τους να είναι πολύ πιο εύκολη και πιο ακριβής.

4.1.3 Περιβάλλον Εργασίας, Επεξεργασία & Εμπλουτισμός Δεδομένων

Το Google Colab αποτέλεσε το κύριο περιβάλλον ανάπτυξης και εκπαίδευσης του μοντέλου (δες Σχήμα 7), καθώς προσφέρει δωρεάν πρόσβαση σε GPU (συνήθως NVIDIA Tesla T4 ή P100) και προρυθμισμένο περιβάλλον Python με εγκατεστημένα πακέτα όπως TensorFlow, Keras και Rasterio. Με τη δυνατότητα σύνδεσης απευθείας στο Google Drive, έγινε εφικτή η εύκολη ανάγνωση και αποθήκευση τόσο των πρώτων δορυφορικών GeoTIFF εικόνων όσο και των παραγόμενων patches, χωρίς να απαιτείται μεταφόρτωση τοπικά. Η χρήση της GPU στο Colab επιτάχυνε αισθητά τους υπολογισμούς κατά την εκπαίδευση — τόσο στην εμπρόσθια διάδοση (forward pass) όσο και στην οπισθοδιάδοση (backward pass) , μειώνοντας δραστικά το χρόνο εκπαίδευσης του δικτύου ανά εποχή (από ώρες ώσε λίγα μόνο λεπτά). Παρά τη σχετική περιορισμένη μνήμη (περίπου 12–16 GB VRAM) και το όριο συνεχούς σύνδεσης (περίπου 12 ώρες), το Colab κρίνεται ιδανικό για έρευνα και πειραματισμό, διότι συνδυάζει ευελιξία, συνεργατικότητα (notebooks μοιράζονται εύκολα) και άμεση πρόσβαση σε υπολογιστικούς πόρους υψηλής απόδοσης.

Σχήμα 7: Το περιβάλλον συγγραφής κώδικα στο Google Colab.

Μετά την αρχική εξαγωγή των δορυφορικών εικόνων, κάθε εικόνα κανονικοποιήθηκε ώστε οι τιμές των εικονοστοιχείων να κυμαίνονται στο διάστημα [0, 1]. Η κανονικοποίηση επιτεύχθηκε με απλή γραμμική μετατόπιση και κλιμάκωση, χρησιμοποιώντας την ακόλουθη σχέση:

$$arr = (arr - arr.min()) / (arr.max() - arr.min() + 1e\text{-}8)$$

ώστε να αποτραπεί η δημιουργία “νεκρών” pixels όταν το εύρος τιμών είναι πολύ μικρό. Επιπλέον, εφαρμόστηκε histogram matching, αξιοποιώντας τη συνάρτηση skimage.exposure.match_histograms, προκειμένου η κατανομή των εντάσεων κάθε εικόνας να προσεγγίζει την κατανομή μιας επιλεγμένης εικόνας αναφοράς. Αυτό εξασφαλίζει ομοιογένεια μεταξύ εικόνων που προέρχονται από διαφορετικές ημερομηνίες ή αισθητήρες, μειώνοντας τις διακυμάνσεις φωτισμού και την πιθανότητα θορύβου στη μάθηση του δικτύου.

Δεδομένου ότι η εξαγωγή και αποθήκευση των πρώτων 200 καθαρών εικόνων από την υπηρεσία Google Earth Engine αποδείχθηκε ιδιαίτερα χρονοβόρα, αποφασίστηκε να μην διευρυνθεί περαιτέρω το αρχικό dataset με επιπλέον λήψεις. Αντιθέτως, για την ενίσχυση των διαθέσιμων δεδομένων εφαρμόστηκαν τεχνικές data augmentation και τεμαχισμού (crops). Συγκεκριμένα, σε κάθε εικόνα εφαρμόστηκαν:

- τυχαίες περιστροφές έως ±15°,
- οριζόντιες και κατακόρυφες αναστροφές,
- καθώς και μετριασμένες αλλαγές στη φωτεινότητα και
- την αντίθεση (±20 %).

Κατόπιν, κάθε εμπλουτισμένη εικόνα υποβλήθηκε σε sliding window τεμάχια 256×256 pixels με βήμα 50 pixels, διατηρώντας μόνο όσα τεμάχια περιείχαν τουλάχιστον 25% δασική βλάστηση. Με τον τρόπο αυτό επιτεύχθηκε ο πολλαπλασιασμός των

δειγμάτων, χωρίς πρόσθετο κόστος λήψεων, και εξασφαλίστηκε η σταθερή τροφοδότηση του U-Net με χιλιάδες patches κατάλληλα για την εκπαίδευσή του.

4.1.4 Εκπαίδευση Νευρωνικού Δικτύου

Για την εκπαίδευση του δικτύου U-Net , του οποίου η αρχιτεκτονική χαρακτηρίζεται από συμμετρική δομή encoder–decoder με πέντε επίπεδα υποδειγματοληψίας και υπερδειγματοληψία. Στο contracting path εφαρμόζονται διαδοχικά ζεύγη συνελικτικών στρωμάτων (Conv2D) με πυρήνες 3×3 και ενεργοποίηση ReLU, ξεκινώντας από 64 φίλτρα στο πρώτο επίπεδο και διπλασιάζοντάς τα σε κάθε βήμα του encoder (128, 256, 512) μέχρι τον πυθμένα, όπου χρησιμοποιούνται 1024 φίλτρα. Κάθε ζεύγος συνελικτικών στρωμάτων ακολουθείται από μία λειτουργία max pooling 2×2, μειώνοντας κατά το ήμισυ τις διαστάσεις του feature map και συγκεντρώνοντας πληροφορία υψηλού επιπέδου. Στο expansive path, η αντίστροφη διαδικασία υλοποιείται με transposed convolutions (Conv2DTranspose) που διπλασιάζουν τις χωρικές διαστάσεις, ενώ μέσω των skip connections συνενώνονται (concatenate) τα αντίστοιχα feature maps από τον encoder, διασφαλίζοντας ότι οι λεπτομερείς χωρικές πληροφορίες παραμένουν διαθέσιμες μέχρι το τελικό επίπεδο.

Η υπερπαραμετροποίηση περιλάμβανε χρήση του Adam optimizer με προεπιλεγμένο ρυθμό μάθησης (learning rate = 0.001) και ελαστικότητα στην επιλογή batch size και epoch. Το δίκτυο εκπαιδεύθηκε για 50 εποχές με batch size = 8, καθώς αυτός ο συνδυασμός εξασφάλισε γρήγορη σύγκλιση χωρίς υπερβολική χρήση μνήμης GPU. Χρήσιμη υπήρξε η παρακολούθηση της απώλειας (sparse_categorical_crossentropy) και της ακρίβειας (accuracy) τόσο για τα δεδομένα εκπαίδευσης όσο και για την validation set, ώστε να εντοπιστεί έγκαιρα τυχόν υπερεκπαίδευση.

Για την αξιολόγηση της απόδοσης εφαρμόστηκε custom metric Mean Intersection over Union (mean_iou_9), που υπολογίζει τον μέσο όρο των IoU για τις εννέα διαθέσιμες κλάσεις. Επιπλέον, μετά την ολοκλήρωση της εκπαίδευσης, υπολογίστηκε για κάθε κλάση το F1-Score, καθώς και precision και recall, προκειμένου να εξεταστεί η ισορροπία μεταξύ false positives και false negatives. Τέλος, το συνολικό Pixel Accuracy επιβεβαίωσε ότι πάνω από το 83 % των pixels ταξινομούνταν σωστά στο test set, ενώ το mean IoU πλησίασε το 0.41, παρέχοντας αξιόπιστη βάση για τη δημιουργία των χαρτών επικινδυνότητας.

Στη φάση της εκπαίδευσης χρησιμοποιήθηκε η GPU του Google Colab, η οποία επέτρεψε την ταυτόχρονη επεξεργασία batch των εικόνων και επιτάχυνε σημαντικά τόσο την εμπρόσθια (forward pass) όσο και την οπισθο-διάδοση (backward pass), εξασφαλίζοντας ολοκλήρωση των 50 εποχών σε μικρό σχετικά χρόνο χωρίς να απαιτηθεί τοπικός εξοπλισμός υψηλών προδιαγραφών.

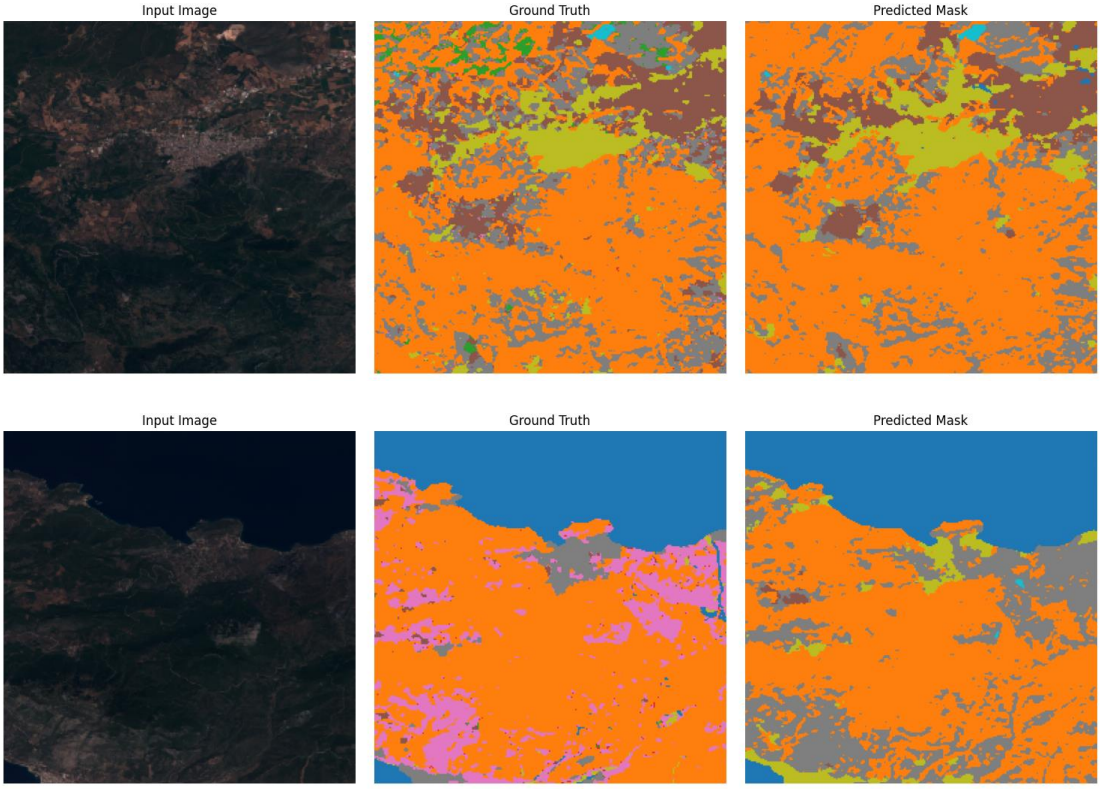

Σχήμα 8: Παραδείγματα αποτελεσμάτων εκπαίδευσης Νευρωνικού Δικτύου σε δορυφορικές εικόνες.

Μερικά παραδείγματα από την εκπαίδευση παρουσιάζονται στο Σχήμα 8. Το μοντέλο σε γενικές γραμμές είχε πολύ καλή επίδοση και έδειξε ότι μπορεί να προβλέψει, με ενθαρρυντικά ποσοστά, εύκολα τις εικόνες. Στην εικόνα για παράδειγμα απεικονίζεται στην αριστερή στήλη μια τυχαίες εκτάσεις γης στην περιοχή της της Ελλάδας, στην μεσαία στήλη η αντίστοιχες ground truths και η δεξιά στήλη αναπαριστά τις προβλέψεις.

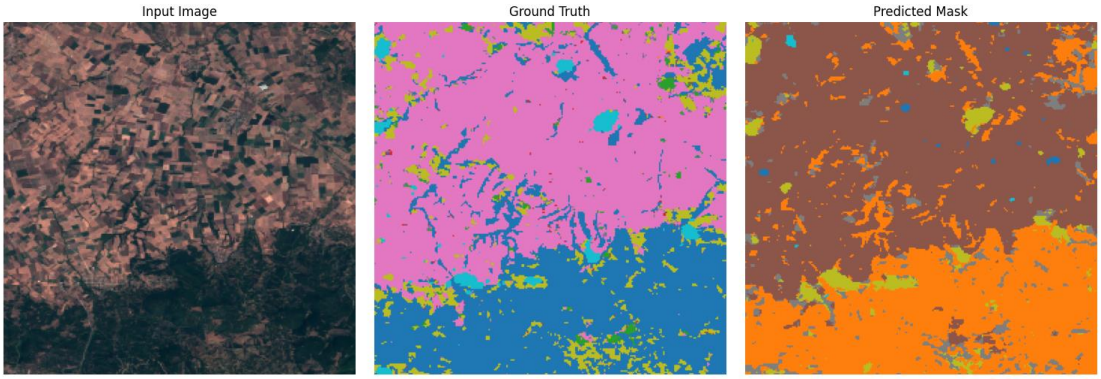

Σχήμα 9: Παράδειγμα εξαίρεσης.

Στο Σχήμα 9 μπορούμε να δούμε μια ειδική περίπτωση κατά την οποία παρόλο που τα δεδομένα είναι λανθασμένα ετικετοποιημένα (η κλάση νερό με μπλε χρώμα βρίσκεται

σε ξεκάθαρη δασική έκταση για παράδειγμα) το U-Net καταφέρνει να ταξινομήσει σωστά τις περιοχές λόγω της ρωμαλαιότητας που απέκτησε κατά τη διαδικασία της εκπαίδευσης. Αποτελεί ένα παράδειγμα ανάδειξης της μηχανικής μάθησης ως τεχνολογία αιχμής.

Στη Γραφική παράσταση 1 του Σχήματος 10 ("Distribution of Precision Across Classes") παρατηρούμε ότι η κλάση 0 (water) καταλαμβάνει το μεγαλύτερο μερίδιο precision, ενώ η κλάση 8 (ice) είναι σχεδόν ανύπαρκτη, λόγω της επιλογής εικόνων από Ελληνικά εδάφη την καλοκαιρινή εποχή, συμπερασματικά δεν προβλέπει σωστά αυτή την κατηγορία. Οι κλάσεις "Trees" (1) και "Shrubs" (5) εμφανίζουν υψηλά ποσοστά precision, υποδεικνύοντας ότι όταν προβλέπονται, η ακρίβειά τους είναι ικανοποιητική. Αντίθετα, οι κλάσεις "Grass " (2) και "Flooded Vegetation" (3) έχουν χαμηλότερα precision, δίνοντας σήμα ότι συχνά είτε συγχέονται μεταξύ τους είτε με το φόντο ("ground").

Στη Γράφική παράσταση 2 στο ίδιο Σχήμα ("Distribution of F1-score Across Classes") το F1-score ενοποιεί precision και recall: εδώ η κλάση 0 εξακολουθεί να πρωτεύει, ενώ οι (1) και "Crops" (4) κλάσεις δείχνουν επίσης καλή ισορροπία ανάμεσα σε false positives και false negatives. Οι (2) και (3) διατηρούν μεσαίες έως χαμηλές τιμές, υπογραμμίζοντας την ανάγκη για βελτιωμένη δειγματοληψία ή ειδικά βήματα augmentation σε αυτές τις κλάσεις.

Τέλος, στη Γραφική παράσταση 3 ("Distribution of IoU Across Classes") αποκαλύπτει ότι η κλάση (0) έχει το υψηλότερο ποσοστό IoU, ακολουθούμενη από την (1), ενώ οι (8) και (2) βρίσκονται στο χαμηλότερο άκρο. Αυτό σημαίνει ότι για τις κλάσεις σχετιζόμενες με το γενικευμένο πρόβλημα έχουν καλά αποτελέσματα ενώ για τις υπόλοιπες δεν έχουμε αρκετά δεδομένα.

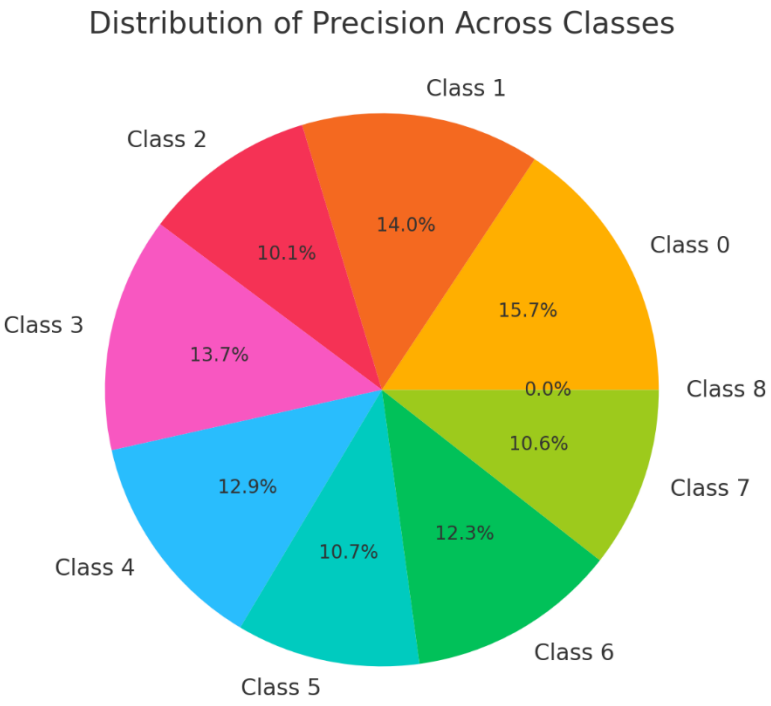

Γραφική παράσταση 1

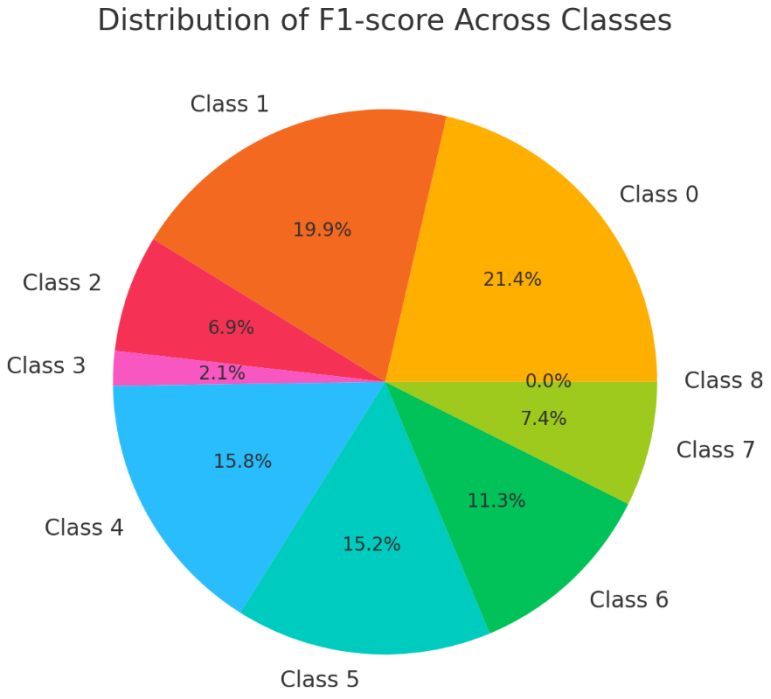

Γραφική παράσταση 2

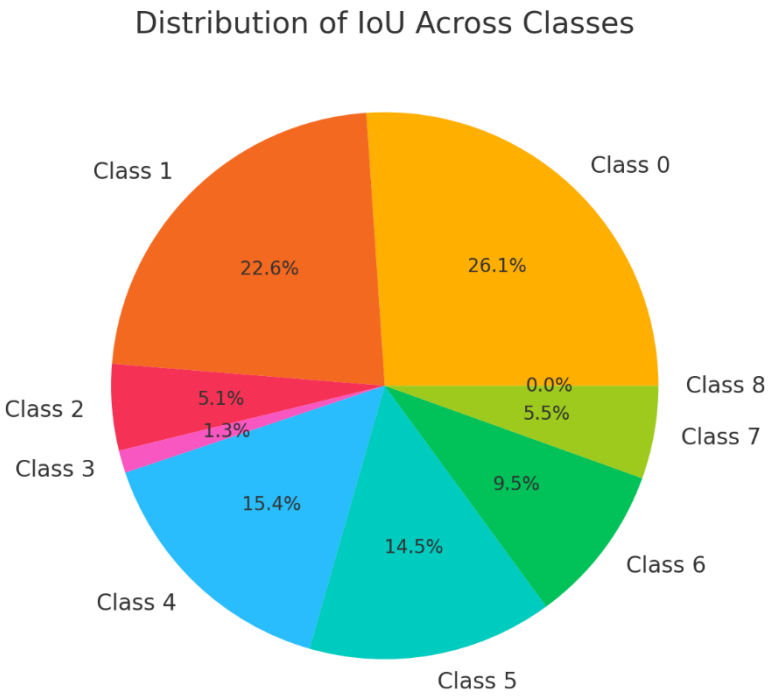

Γραφική παράσταση 3

Σχήμα 10: Αποτελέσματα εκπαίδευσης με μορφή γραφικών παραστάσεων.

Αυτές οι γραφικές παραστάσεις διευκολύνουν τη σύγκριση των κλάσεων και τον εντοπισμό σε ποια αντικείμενα το δίκτυο αποδίδει καλύτερα ή χειρότερα, βοηθώντας στη λήψη αποφάσεων για βελτιώσεις και τροποποιήσεις του συνόλου δεδομένων.

Ο βασικός κώδικας βρίσκεται στο Παράρτημα Κώδικα (Listing 2). Δε θα δοθεί περαιτέρω έμφαση στο κομμάτι εκπαίδευσης μέσω δορυφορικών εικόνων, διότι η διαδικασία αυτή έγινε για λόγους εξοικείωσης με το U-Net και την εκπαίδευση γενικότερα. Επομένως το ενδιαφέρον μπορεί να μεταφερθεί στις UAV εικόνες, που αποτελεί και τη βάση στην εργασία αυτή.

4.2 Εκπαίδευση με UAV Εικόνες

4.2.1 Περιορισμοί & Τελικό Pipeline

Κατά την υλοποίηση του προτεινόμενου συστήματος εντοπίστηκαν ορισμένοι κρίσιμοι περιορισμοί υλικού και λογισμικού, η αντιμετώπιση των οποίων θα ενίσχυε σημαντικά την ποιότητα των αποτελεσμάτων. Αρχικά, το διαθέσιμο drone δεν υποστήριζε περιβάλλον ανάπτυξης κώδικα επί πτήσης ούτε διέθετε επαρκή υπολογιστική ισχύ για onboard επεξεργασία εικόνας—παράγοντες που οφείλονται στην ταχύτατη εξέλιξη μπαταριών και firmware τα τελευταία έτη. Ως αποτέλεσμα, δεν ήταν δυνατή η

αυτόματη σχεδίαση πτήσεων με σταθερή διαφορά ύψους ή προσαρμογή του πεδίου λήψης σε πραγματικό χρόνο. Η παράμετρος του ύψους λήψης, κρίσιμη για τη συνεπή ανάλυση της βλάστησης, εισήχθη τελικά εμπειρικά κατά το στάδιο της ετικετοποίησης, επηρεάζοντας την ομοιογένεια του dataset.

Επιπλέον, η έλλειψη προηγούμενης εμπειρίας στη διαδικασία labeling είχε ως συνέπεια την εμφάνιση σφαλμάτων στην αρχική σήμανση των εικόνων. Παρά τις προσπάθειες διορθώσεων με μετα-επεξεργασία (thresholding, median filtering) και τυχαίο έλεγχο ποιότητας, κάποια λάθη παρέμειναν και επηρέασαν μετρήσιμα τα metrics απόδοσης.

Τέλος, οι περιορισμένοι υπολογιστικοί πόροι, δηλαδή περιορισμένη μνήμη GPU και χρόνος εκτέλεσης, επέβαλαν την επιλογή σχετικά μικρού training set, περιορίζοντας την ποικιλία των δειγμάτων και την πολυπλοκότητα του μοντέλου. Η αύξηση της διαθεσιμότητας επεξεργαστικής ισχύος και η ενσωμάτωση τεχνικών distributed training θα επέτρεπαν τη χρήση ευρύτερων datasets και την εφαρμογή πιο απαιτητικών αρχιτεκτονικών, οδηγώντας σε περαιτέρω βελτίωση της ακρίβειας και της γενίκευσης του μοντέλου.

Το απεικονιζόμενο pipeline στο Σχήμα 11 ξεκινάει με τη λήψη υψηλής ανάλυσης εικόνων από το drone, οι οποίες αποθηκεύονται τοπικά για περαιτέρω επεξεργασία. Κάθε πλήρης εικόνα κόβεται σε μικρότερα patches (cropped images) έτσι ώστε να ταιριάζει στο απαιτούμενο μέγεθος εισόδου του νευρωνικού δικτύου.

Στη συνέχεια, τα patches τροφοδοτούνται στο εκπαιδευμένο semantic-segmentation μοντέλο (U-Net), το οποίο παράγει για κάθε pixel μια κατηγορία ετικέτας (π.χ. ground, bush, big tree κ.λπ.). Αυτές οι μάσκες συγκεντρώνονται ξανά στην αρχική γεωγραφική διάταξη, προκειμένου να ανασυστήσουμε την πλήρη, κατηγοριοποιημένη εικόνα (“segmented images”).

Το επόμενο στάδιο είναι η αξιολόγηση της επικινδυνότητας: κάθε κατηγορία ετικέτας αποδίδει ένα προεπιλεγμένο βάρος (risk weight), και με τη βοήθεια ενός απλού evaluator υπολογίζεται η «ένταση κινδύνου» σε κάθε pixel. Το αποτέλεσμα είναι ένας χάρτης έντασης κινδύνου (danger intensity map), ο οποίος απεικονίζει με διαβαθμίσεις χρώματος τις πιο επικίνδυνες ζώνες.

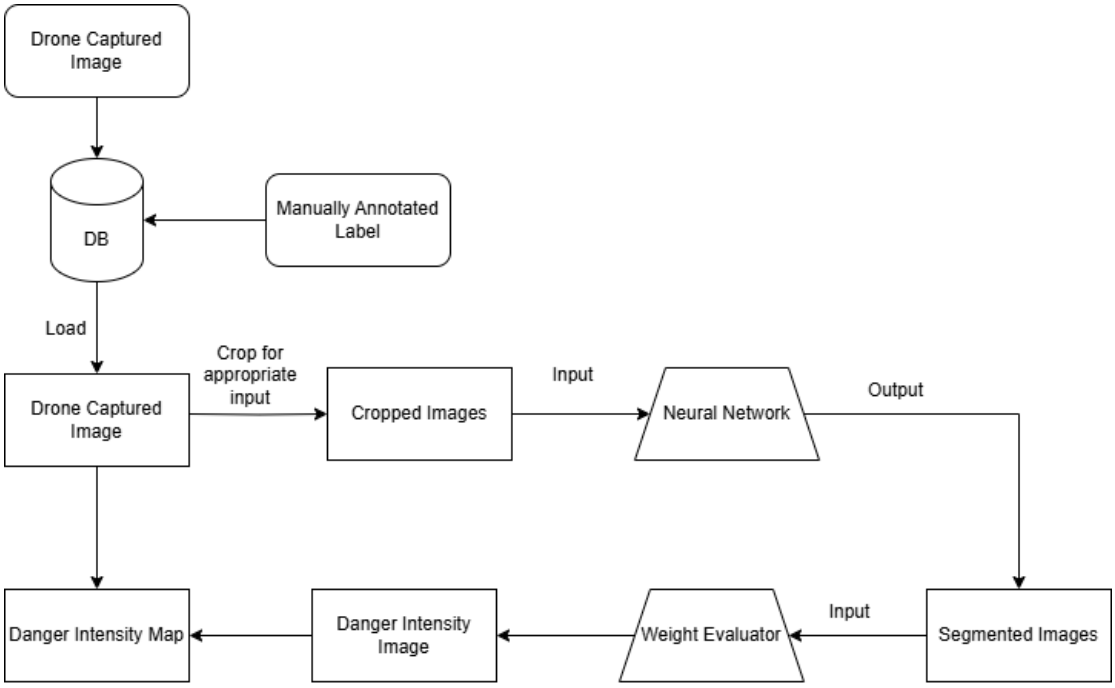

Σχήμα 11: Το pipeline προς υλοποίηση.

4.2.2 Σχεδιασμός & Πτήση Drone

Για τη συλλογή εικόνων UAV επιλέχθηκε το μοντέλο DJI Phantom 4 Pro (δες Σχήμα 12), το οποίο δεν απαιτεί ειδική πιστοποίηση χειριστή για πτήσεις εντός πανεπιστημιακών εγκαταστάσεων. Όλες οι πτήσεις περιορίστηκαν στο campus και εκτελέστηκαν σε ύψος 100 m, ώστε να τηρούνται οι ισχύουσες κανονιστικές διατάξεις. Η ενσωματωμένη κάμερα 1″ CMOS με οριζόντιο οπτικό πεδίο περίπου 84° αποτύπωσε εύρος εδάφους περίπου 180 m στον ορίζοντα, το οποίο αντιστοιχεί—με ανάλυση εικόνας 5 472 px οριζόντια—σε χωρική ανάλυση περίπου 3.3 cm/pixel (Ground Sampling Distance). Κάθε pixel καλύπτει έτσι επιφάνεια περίπου 0,001 m², διασφαλίζοντας την επαρκή λεπτομέρεια για subsequent semantic segmentation (Σχήμα12).

Παρά το υψηλό ποιοτικό επίπεδο εικόνων (20 MP) και τη σταθερότητα πτήσης, η πλατφόρμα δεν υποστηρίζει onboard επεξεργασία πέραν βασικής βιντεοσυγκέντρωσης· όλες οι λειτουργίες segmentation και labeling υλοποιούνται μεταγενέστερα σε περιβάλλον workstation. Η διαχείριση δεδομένων μέσω DJI SDK παρουσιάζει περιορισμούς στη μετάδοση live stream (latency, απώλεια καρέ) και απαιτεί πολύπλοκο συγχρονισμό του κώδικα με το ground station.

Η σχεδίαση της αποστολής περιελάμβανε πλάτος διαδρομής 60 m (λόγω περιορισμένου διπλώματος πιλότου drone), ύψος πτήσης 100 m και overlap > 70 % τόσο οριζόντια όσο και κατακόρυφα, ώστε να εξασφαλίζεται επαρκής επικαλυπτικότητα για orthomosaic stitching και consistent coverage. Επιπλέον ελήφθησαν υπόψη η διάρκεια πτήσης (~27 min ανά μπαταρία), η ανοιξιάτικη εποχή

για την χρωματικά πλούσια βλάστηση, οι συνθήκες φωτισμού κατά τις μεσημεριανές πτήσεις (αποφυγή έντονης σκίασης) και οι καιρικές παράμετροι (άνεμοι έως 5 m/s), εξασφαλίζοντας σταθερή ποιότητα λήψης και ομαλή ροή δεδομένων για το επόμενο στάδιο της μεθοδολογίας.

Σχήμα 12: DJI Phantom 4 Pro Drone.

4.2.3 Δημιουργία Κλάσεων & Ετικετοποίηση UAV Dataset

Στο πλαίσιο της συλλογής δεδομένων πραγματοποιήθηκαν συνολικά 100 λήψεις εικόνων, μέσω των οποίων εξασφαλίσθηκε επαρκής ποικιλία συνθηκών φωτισμού. Από αυτές τις λήψεις επιλέχθηκαν για χειροκίνητη ετικετοποίηση δέκα εικόνες (δες Σχήμα 13) με πλούσιο περιεχόμενο σε κλάσεις βλάστησης και υποδομών. Το σχετικά μεγάλο μέγεθός τους επέτρεψε τη δημιουργία 2520 τεμαχίων (patches) διαστάσεων 256×256 pixels, τα οποία τροφοδοτούν απευθείας το U-Net. Παρά την επάρκεια αυτού του όγκου δειγμάτων, οι περιορισμένοι υπολογιστικοί πόροι, π.χ. διαθέσιμη μνήμη GPU και χρόνος εκπαίδευσης στο Google Colab, περιορίζουν την εκπαίδευση σε χαμηλότερο batch size και αριθμό epochs, με αποτέλεσμα τα εκπαιδευτικά πειράματα να μην αξιοποιούν πλήρως τη δυνατότητα βελτιστοποίησης των υπερπαραμέτρων και να αποδίδουν υποβέλτιστα τελικά metrics.

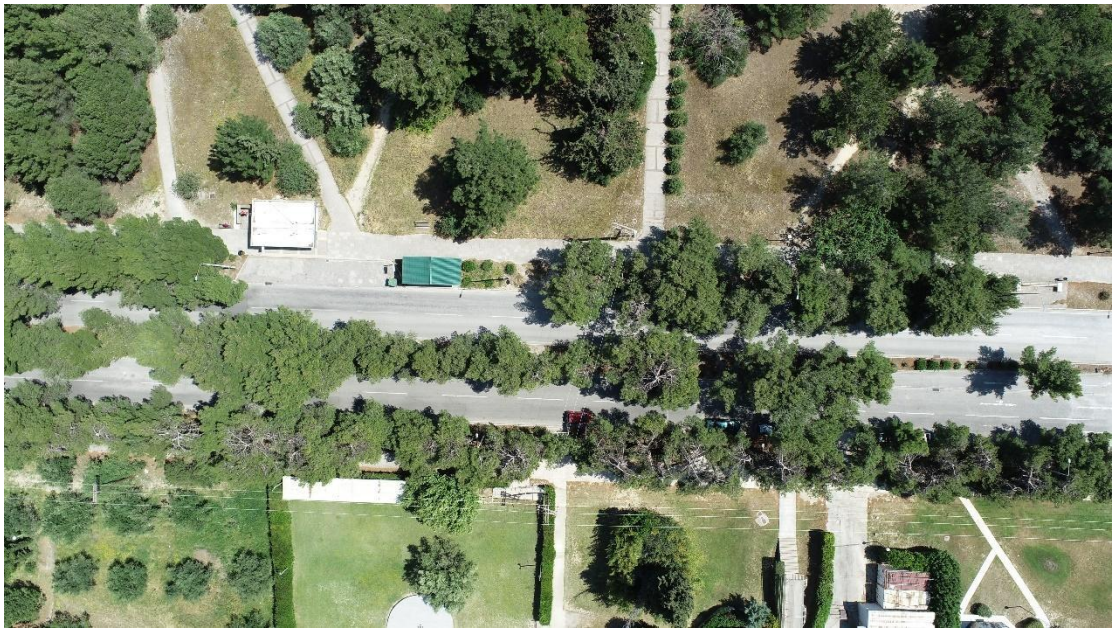

Σχήμα 13: Παράδειγμα λήψης από το drone στον χώρο του πανεπιστημίου.

Καθορίστηκαν επτά κλάσεις ετικετοποίησης που αντανακλούν την επικινδυνότητα και τη λειτουργική σημασία της βλάστησης και των ανθρωπογενών στοιχείων σε πεδία δασικών πυρκαγιών:

Έδαφος & υποστρώματα (ground)

Η κλάση «Έδαφος & υποστρώματα», όπως για παράδειγμα φαίνεται στο Σχήμα 14, περιλαμβάνει γυμνό έδαφος που συχνά καλύπτεται από λεπτά στρώματα ξερών χόρτων, πευκοβελονών, φλοιού και υπολειμμάτων κλαδιών, τα οποία, αν και δεν θεωρούνται παραδοσιακά «βαριά» καύσιμα, λειτουργούν ως πυροδοτικοί παράγοντες και «γέφυρες» μεταφοράς της φωτιάς. Τα λεγόμενα fine fuels παρουσιάζουν χαμηλή περιεκτικότητα σε υγρασία και υψηλό λόγο επιφάνειας προς όγκο, μειώνοντας αισθητά τον χρόνο ανάφλεξης και επιταχύνοντας τη διάδοση της φλόγας στο υπόλοιπο φυτικό στρώμα. Επιπλέον, τόσο η κλίση όσο και η υφή του εδάφους επιδρούν στην ταχύτητα διάδοσης: σε ανηφορικές κλήσεις η φωτιά κινείται ταχύτερα, ενώ σε συμπιεσμένα στερεά υποστρώματα, όπως χωματόδρομοι ή

Σχήμα 14: Παράδειγμα κλάσης ground.

ζώνες πυροπροστασίας, η μετάδοση επιβραδύνεται, λειτουργώντας εν μέρει ως φυσικό μέσο αναχαίτισης. Η ακριβής αναγνώριση και χαρτογράφηση αυτής της κλάσης μέσω semantic segmentation επιτρέπει τη λεπτομερή απεικόνιση περιοχών όπου το έδαφος συμβάλλει στην αρχική εξάπλωση, τον στοχευμένο σχεδιασμό εργασιών καθαρισμού για αφαίρεση των fine fuels και την αξιολόγηση της αποτελεσματικότητας υφιστάμενων αντιπυρικών ζωνών

Θάμνοι & χόρτα (bush)

Η κλάση «Θάμνοι & χόρτα» περιλαμβάνει τόσο χαμηλής ως μεσαίας ανάπτυξης θαμνώδη βλάστηση (όπως σπάρτα, σχίνοι, ασπαρτούσες) όσο και ξηρά, χόρτα που σχηματίζουν πυκνά πατώματα. Η δομή αυτή συνδυάζει μεγάλο όγκο ξηρής φυτικής ύλης με υψηλό λόγο επιφάνειας–προς–όγκο (SA/V), γεγονός που ευνοεί την ταχεία εξάπλωση της φλόγας κατά μήκος των θάμνων και των χόρτων. Επίσης, η μικτή παρουσία πράσινων και ξηρών στοιχείων δημιουργεί ζώνες μεταβαλλόμενης επιδεκτικότητας στη φωτιά, όπου τα πρώτα σημεία ανάφλεξης μπορεί να εντοπιστούν σε ξερά χόρτα, που στη συνέχεια μεταφέρουν τη φλόγα σε πιο πυκνούς θάμνους (δες Σχήμα 15). Στα ημιαστικά και ημιαγροτικά περιβάλλοντα, όπου η πρόσβαση για καθαρισμό είναι δύσκολη, η σωστή χαρτογράφηση αυτής της κλάσης μέσω semantic segmentation επιτρέπει την προτεραιοποίηση περιοχών για fuel treatment και την έγκαιρη κινητοποίηση μέτρων πρόληψης.

Σχήμα 15: Παραδείγματα της κλάσης bush.

Μεσαίας επικινδυνότητας δέντρα (mid tree)

Στην κατηγορία «Μεσαίας επικινδυνότητας» εντάσσονται είδη όπως τα κυπαρισσοειδή και οι ελιές αριστερά και δεξιά αντιστοίχως (δες Σχήμα 16). Τα κυπαρισσοειδή, παρά το μεγάλο ύψος τους, παρουσιάζουν στενή κόμη και υψηλή υγρασία ξύλου, με αποτέλεσμα μικρό συνολικό όγκο βιομάζας και αργό ρυθμό εξάπλωσης της φωτιάς. Αντίστοιχα, οι ελιές διαθέτουν μέτριο ύψος και πλάτος, παχύτερα φύλλα πλούσια σε λιγνίνη και μέτρια πυκνότητα στελεχών, παράγοντες που επιμηκύνουν το χρόνο ανάφλεξης και επιβραδύνουν την καύση.

Σχήμα 16: Παραδείγματα κλάσης mid tree.

Υψηλής επικινδυνότητας δέντρα (big tree)

Στην κατηγορία «Υψηλής επικινδυνότητας δέντρα» εντάσσονται όλα τα είδη με μεγάλο όγκο βιομάζας και λεπτά, ευφλεκτά φύλλα ή βελόνες, τα οποία λειτουργούν ως «καύσιμα» που τροφοδοτούν γρήγορα και έντονα τη φωτιά (δες Σχήμα 17). Τυπικά παραδείγματα είναι το πεύκο (Pinus spp.), όπως στο αριστερό στιγμιότυπο, όπου οι λεπτές βελόνες και ο ρητινώδης φλοιός επιταχύνουν τόσο την ανάφλεξη όσο και τη διάδοση της φλόγας, και ο ευκάλυπτος (Eucalyptus spp.), όπως στη δεξιά εικόνα, ο οποίος, παρά τον σχετικά αδρό φλοιό του, συγκεντρώνει μεγάλο όγκο αιθέριων ελαίων στα φύλλα και σχηματίζει παχιά στρώματα ξερών φλοιών στο έδαφος, δημιουργώντας ταχύτατο «καύσιμο» για την πυρκαγιά.

Σχήμα 17: Παραδείγματα κλάσης big tree.

Δικτυακός εξοπλισμός υψηλής τάσης (electrical)

Η κατηγορία «Δικτυακός εξοπλισμός υψηλής τάσης» αντιστοιχεί σε υποσταθμούς, πυλώνες και καλώδια διανομής ρεύματος, τα οποία αποτελούν κρίσιμους κόμβους στον χάρτη κινδύνου. Όταν τα κλαδιά των δέντρων πλησιάζουν επικίνδυνα τα καλώδια (δες Σχήμα 18), αυξάνεται σημαντικά ο κίνδυνος δημιουργίας σπινθήρων ή βραχυκυκλωμάτων, που μπορούν να πυροδοτήσουν φωτιά. Επιπλέον, τυχόν πτώση τμήματος καλωδίου ή ζημιά σε μονωτήρα μεταφέρει ζωντανά ηλεκτρόδια σε επαφή με καύσιμα, πολλαπλασιάζοντας τις πιθανότητες ανάφλεξης σε ξηρές συνθήκες.
Η συστηματική χαρτογράφηση αυτών των υποδομών, μαζί με την κοντινή βλάστηση, επιτρέπει την έγκαιρη εντοπισμό «σημείων υψηλού ηλεκτρικού κινδύνου» και τον προγραμματισμό προληπτικών εργασιών κλαδέματος ή αξιολόγησης της μόνωσης.

Σχήμα 18: Παράδειγμα κλάσης electrical.

Στο τελικό μοντέλο, η κλάση αυτή σημειώνεται για λόγους επικινδυνότητας αλλά δεν εισάγεται στη διαδικασία διάδοσης της φωτιάς, καθώς τα καλώδια δεν λειτουργούν ως καύσιμη ύλη· αντίθετα, η ανίχνευσή τους στοχεύει στην αποτροπή ηλεκτρικών ατυχημάτων που μπορεί να προκαλέσουν ή να εντείνουν εστίες πυρκαγιάς.

Δρόμοι (road)

Η κατηγορία «Δρόμοι» περιλαμβάνει ασφαλτοστρωμένους και χωματόδρομους που λειτουργούν τόσο ως πιθανοί επιβραδυντές διάδοσης της φωτιάς, λόγω της απουσίας καύσιμης βιομάζας στην επιφάνειά τους, όσο και ως βασικοί άξονες πρόσβασης για τις πυροσβεστικές δυνάμεις. Η ακριβής χαρτογράφηση των δρόμων επιτρέπει τον σχεδιασμό βέλτιστων διαδρομών επέμβασης και την εκτίμηση χρόνων άφιξης στις εστίες, ενώ βοηθά στον εντοπισμό σημείων όπου η φλόγα θα μπορούσε να «πηδήξει» από την καυστική ζώνη στο γειτονικό δάσος (π.χ. ανώμαλα πρανή ή κενά φύτευσης). Επιπλέον, κάθε αντικείμενο που εντοπίζεται πάνω στην επιφάνεια του οδοστρώματος, ή και του πεζοδρομίου μιας και έχουν ίδιες ιδιότητες (δες Σχήμα 19), όπως οχήματα, κάδοι ή πασσάλους, κατηγοριοποιείται επίσης στη «Δρόμοι» για να αποφευχθεί η σύγχυση με άλλα είδη καύσιμης ύλης και να διασφαλιστεί η ακρίβεια των χαρτών πρόσβασης.

Σχήμα 19: Παράδειγμα κλάσης road.

Κτίρια & ανθρωπογενείς κατασκευές (building)

Η κατηγορία «Κτίρια & ανθρωπογενείς κατασκευές» λειτουργεί ανάλογα με την κλάση των δρόμων, καθώς οι επιφάνειές τους—ασφαλτοστρωμένες ή τσιμεντένιες—δεν τροφοδοτούν άμεσα τη φωτιά. Ωστόσο, τα κτίρια και οι συναφείς κατασκευές (δες Σχήμα 20) παρουσιάζουν ένα μικρό πρόσθετο βαθμό επικινδυνότητας, λόγω της ύπαρξης ξύλινων ή άλλων ευφλεκτών στοιχείων (π.χ. κουφώματα, τέντες, ξύλινα κιόσκια) που μπορούν να συμβάλουν στην αρχική διάδοση της φλόγας. Στην παρούσα ταξινόμηση έχουν συμπεριληφθεί επίσης όλα τα αντικείμενα που, από την οπτική γωνία των UAV, εμφανίζονται ως κτίρια ή κατασκευές, όπως οι τέντες της δεξιάς εικόνας, προκειμένου να διασφαλιστεί η ακρίβεια του χάρτη πρόσβασης και να αποφευχθεί η παρανόηση με παρακείμενα καύσιμα.

Σχήμα 20: Παράδειγμα κλάσης building.

Η ετικετοποίηση των UAV εικόνων έγινε με πολυγωνική σήμανση στο VGG Image Annotator (δες Σχήμα 21), με ιδιαίτερη προσοχή στα όρια κάθε περιοχής· η λεπτομέρεια αυτή διασφάλισε ακριβή διάκριση των κλάσεων και διατήρηση των χαρακτηριστικών των αντικειμένων, παρά την πολυπλοκότητα του τοπίου. Η εξαγωγή έγινε με τη μορφή JSON αρχείου.

Κάθε εικόνα χρειάστηκε 6 ώρες κατά μέσο όρο και είχε περίπου 250 ετικετοποιημένες περιοχές με κατανομή των pixel:

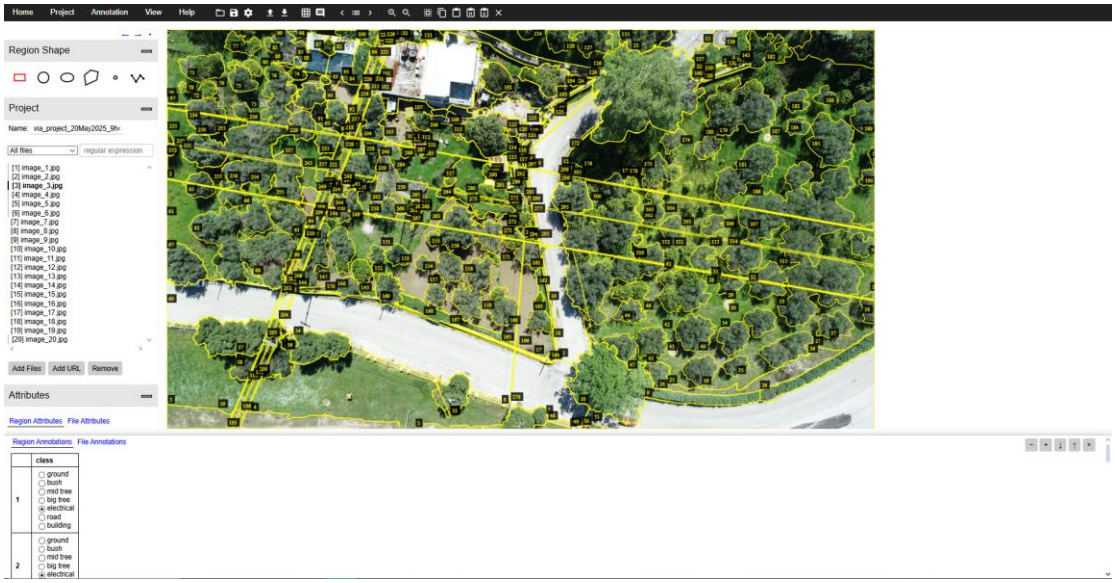

Σχήμα 21: Το περιβάλλον ετικετοποίησης VGI.

Για τη μετατροπή των ετικετών από το JSON αρχείο σε εικόνες μάσκας χρησιμοποιήθηκε ένα αυτοματοποιημένο σκριπτ, αναγράφεται στο Παράρτημα κώδικα (Listing 3), όπου αφού εισήγαγε τα δεδομένα της εξαγόμενης VIA ετικετοποίησης, αντιστοιχούσε κάθε πολυγωνική περιοχή στην κατάλληλη κλάση με βάση ένα προκαθορισμένο χάρτη χρωμάτων (π.χ. “ground” → κόκκινο, “bush” → σκούρο καστανό). Κατά τη διαδικασία, το σκριπτ εντόπιζε και συμπλήρωνε αυτόματα τυχόν κενά – pixels που δεν ανήκαν σε καμία περιοχή – με τη μέθοδο της εγγυτάτης απόστασης (Voronoi), ώστε να μην παραμένουν άδειες ζώνες στο τελικό μάσκα. Στο τέλος, κάθε μάσκα αποθηκευόταν σε μορφή PNG, διατηρώντας τη γεωγραφική διάσταση της αντίστοιχης RGB εικόνας. Με αυτόν τον τρόπο εξασφαλίστηκε η δημιουργία έτοιμων για εκπαίδευση μάσκων, χωρίς να απαιτείται επιπλέον χειροκίνητη διόρθωση ή συμπλήρωση.

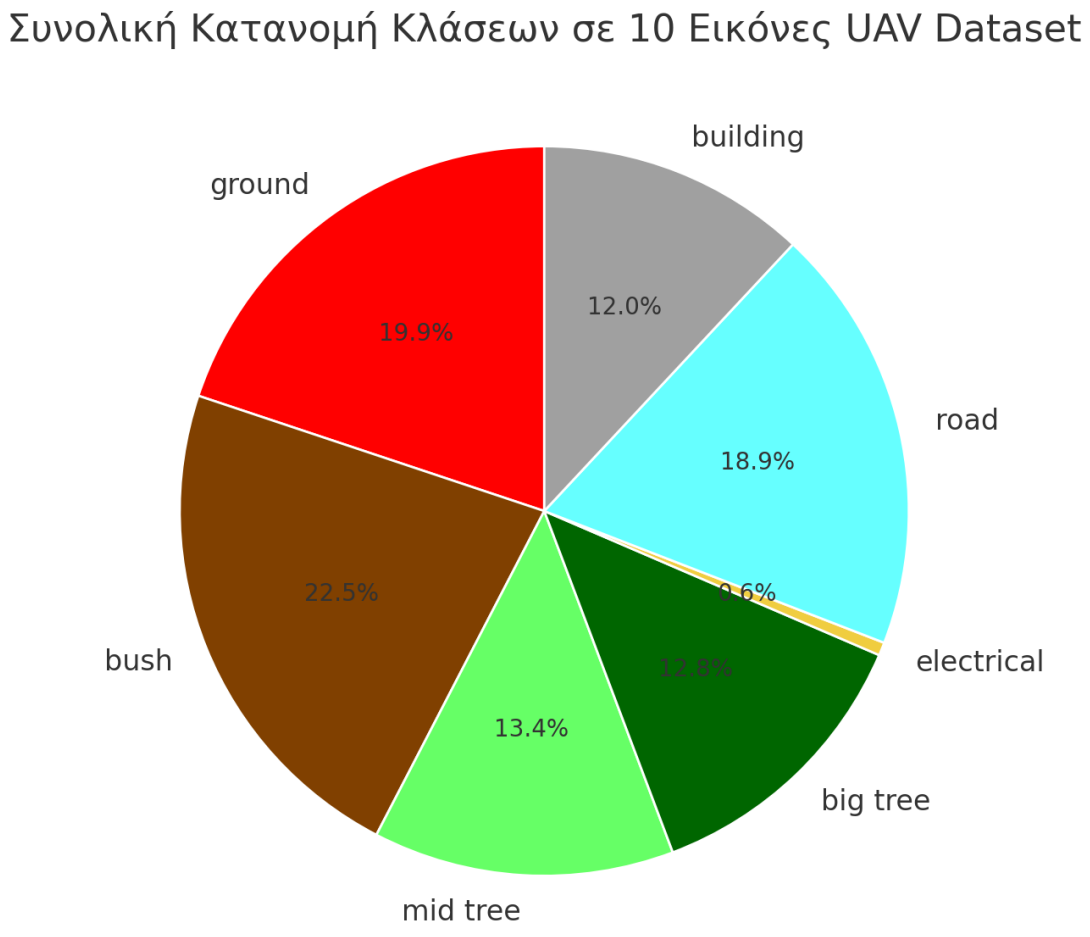

Γραφική Παράσταση 1

Σχήμα 22: Η κατανομή των κλάσεων των pixel και των χρωμάτων.

Η συνολική κατανομή των κλάσεων στο σετ των 10 UAV εικόνων, όπως υποδεικνύει η Γραφική Παράσταση 1 (δες Σχήμα 22), αποκαλύπτει σημαντικές ανισορροπίες: η μεγαλύτερη συμμετοχή ανήκει στους «θάμνους» (22,5 %) και στο «έδαφος» (19,9 %), ενώ οι «δρόμοι» καλύπτουν το 18,9 %. Οι κλάσεις «μεσαίας επικινδυνότητας δέντρων» και «υψηλής επικινδυνότητας δέντρων» αντιστοιχούν σε 13,4 % και 12,8 % αντίστοιχα, με τα «κτίρια» να φτάνουν το 12,0 %. Αντίθετα, ο «δικτυακός εξοπλισμός» είναι σχεδόν ανύπαρκτος (0,6 %), γεγονός που καθιστά αναγκαία είτε την τεχνητή αύξησή του μέσω augmentation είτε την εφαρμογή βαρών κατά την εκπαίδευση, ώστε το μοντέλο να μάθει να τον αναγνωρίζει αξιόπιστα. Η σχετική υποαναπαράσταση των «big tree» (12,8 %) σε σχέση με τους «θάμνους» και το «έδαφος» υποδεικνύει επίσης την ανάγκη για ισορροπημένη δειγματοληψία, ειδικά εάν η αποδοτική ανίχνευση μεγάλων δέντρων αποτελεί κρίσιμο στόχο για την πρόληψη διάδοσης της φωτιάς.

4.2.4 Προεπεξεργασία & Augmentation

Για την αντιμετώπιση της έλλειψης δειγμάτων υψηλής επικινδυνότητας (big-tree) στο αρχικό dataset, εφαρμόστηκε στο στάδιο του διαμερισμού των δεδομένων σε σετ εκπαίδευσης, επικύρωσης, δοκιμής, (train/val/test split) ένας μηχανισμός «ενίσχυσης» της αναλογίας τους. Συνολικά παραχθήκαν 2 520 patches, εκ των οποίων 704 αντιστοιχούν σε κλάση big-tree και 1 816 σε όλες τις υπόλοιπες κλάσεις. Κατά την κατανομή, το training set περιέχει 2 085 δείγματα (συμπεριλαμβανομένων 633 big-tree), το validation set 217 δείγματα (35 big-tree) και το test set 218 δείγματα (36 big-tree). Με αυτόν τον τρόπο διασφαλίζεται ότι το δίκτυο «βλέπει» επαρκή ποικιλία και αριθμό δειγμάτων των πλέον επικίνδυνων δασικών τύπων, βελτιώνοντας την ικανότητά του να μαθαίνει και να γενικεύει την ανίχνευση των κρίσιμων αυτών περιοχών.

Στη συγκεκριμένη περίπτωση λόγω του όγκου των δεδομένων (2520 crops μεγέθους 256x256 pixel) όπως για παράδειγμα φαίνεται στο Σχήμα 23, δε ήταν αναγκαία η δημιουργία επιπλέον δειγμάτων για να είναι επαρκής η διαδικασία της εκπαίδευσης

Σχήμα 23: Παράδειγμα εισόδου στο δίκτυο.

4.2.5 Εκπαίδευση & Βελτιστοποίηση

Χρησιμοποιήθηκε το ίδιο μοντέλο για την διαδικασία της εκπαίδευσης των UAV εικόνων με αυτό των δορυφορικών εικόνων, όπως και οι ίδιες παράμετροι.

Τα διαγράμματα του Σχήματος 24 απεικονίζουν την εξέλιξη των δύο βασικών μετρικών κατά τη διάρκεια της εκπαίδευσης του U-Net. Συγκεκριμένα:

- στη Γραφική Παράσταση 1 παρουσιάζονται οι τιμές της training και της validation accuracy ανά εποχή. Η εκπαίδευση ξεκινά με accuracy περίπου 0,26 στο training set, αυξάνεται ταχέως τις πρώτες δέκα εποχές έως και 0,57 και σταδιακά συγκλίνει γύρω στο 0,63, ενώ η validation accuracy διατηρείται σε ελαφρώς υψηλότερα επίπεδα, υποδεικνύοντας ομαλή πορεία μάθησης χωρίς έντονη υπερεκπαίδευση (overfitting).
- Αντίστοιχα, η Γραφική Παράσταση 2 απεικονίζει την πορεία του mean IoU για training και validation. Η αρχική τιμή του IoU στο training set είναι περίπου 0,08 και στο validation set περίπου 0,19· στο τέλος της εκπαίδευσης το training IoU φτάνει στο 0,37 και το validation IoU στο 0,30, επιβεβαιώνοντας ότι το μοντέλο μαθαίνει σταδιακά να αναγνωρίζει με μεγαλύτερη ακρίβεια τις επιμέρους κλάσεις στο segmentation. Η τελική αξιολόγηση στο test set ανέδειξε accuracy = 0,6371 και mean IoU = 0,2985, αποτελέσματα που καταδεικνύουν την ικανοποιητική απόδοση του U-Net στο συγκεκριμένο UAV dataset.

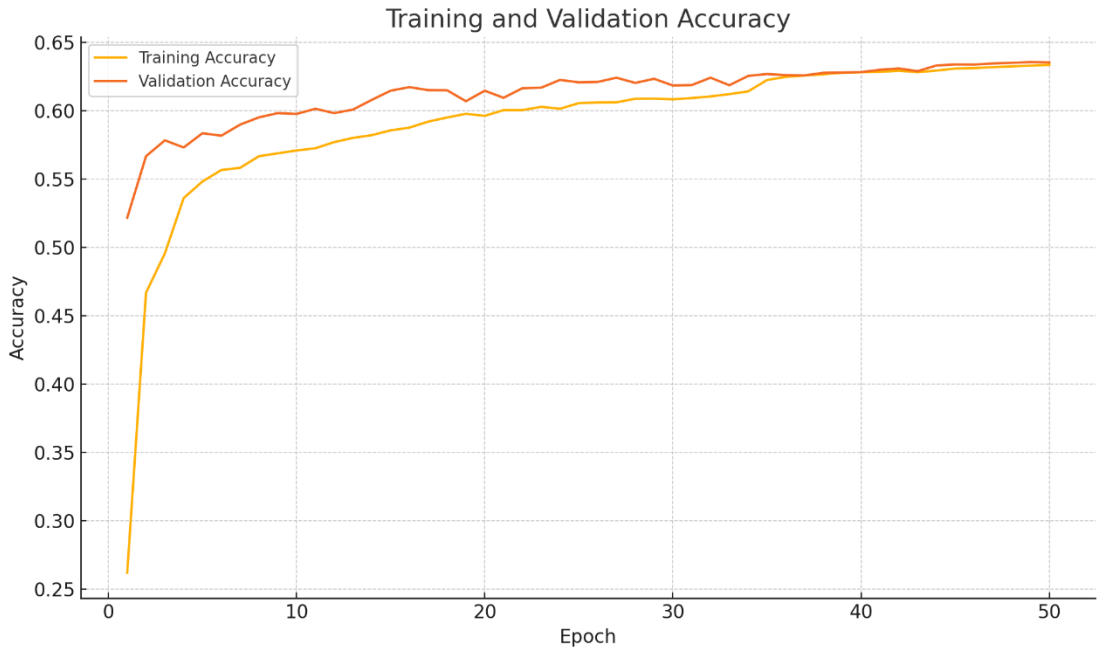

Γραφική Παράσταση 1

Γραφική Παράσταση 2

Σχήμα 24: Αποτελέσματα εκπαίδευσης με μορφή γραφικών παραστάσεων.

Περαιτέρω βελτίωση της απόδοσης αναμένεται με χρήση μεγαλύτερων training datasets, fine-tuning υπερπαραμέτρων ή ενσωμάτωση συμπληρωματικών πηγών δεδομένων. Ο πλήρης κώδικας εκπαίδευσης περιλαμβάνεται στο Παράρτημα (Listing 4).

ΚΕΦΑΛΑΙΟ 5

Πειραματικά Αποτελέσματα

Σε αυτό το κεφάλαιο εξετάζονται τα πειραματικά αποτελέσματα και οι μετέπειτα εφαρμογές της εκπαίδευσης σε UAV εικόνες. Στη Γραφική Παράσταση 1 (δες Σχήμα 25), φαίνεται το Intersection over Union metric για κάθε κλάση του γραφήματος.

Παρατηρούμε ότι στις ξεκάθαρες κλάσεις:

- road και
- building

η επιδόσεις του δικτύου είναι αρκετά καλές.

Ωστόσο όσον αφορά τις κλάσεις βλάστησης, λόγω τις ομοιότητας τους η επίδοση του δεν είναι και τόσο καλή. Στη Γραφική Παράσταση 2, όπου απεικονίζονται τα δεδομένα με τη μορφή confusion matrix, βλέπουμε ότι τα στοιχεία της διαγωνίου είναι αυτά που θα πρέπει να έχουν υψηλές τιμές.

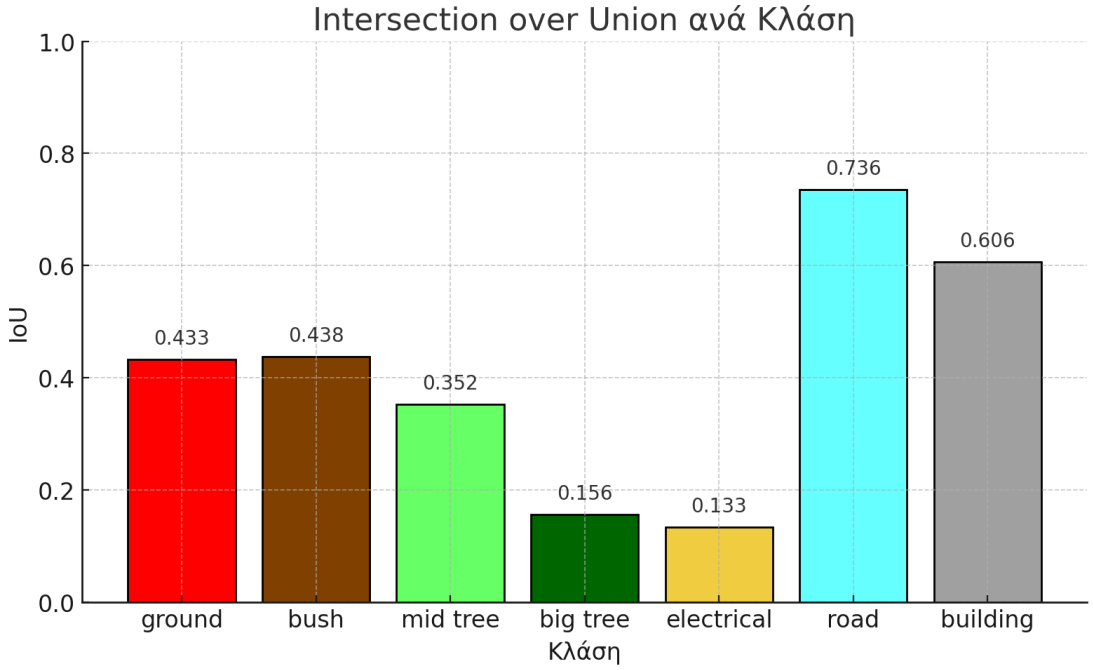

Γραφική Παράσταση 1

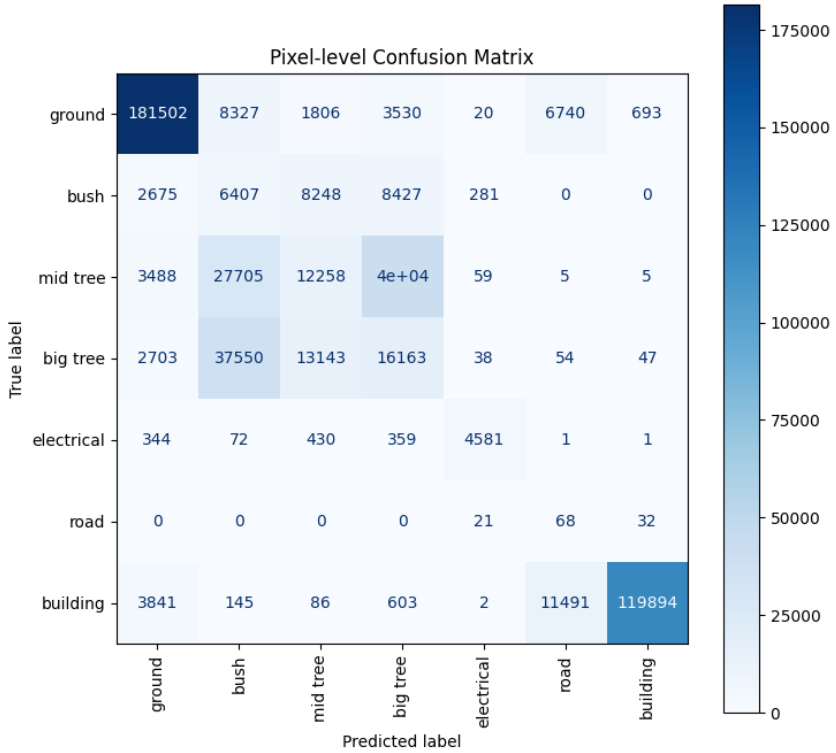

Γραφική Παράσταση 2

Σχήμα 25:Μετρικές εκπαίδευσης με μορφή γραφικών παραστάσεων.

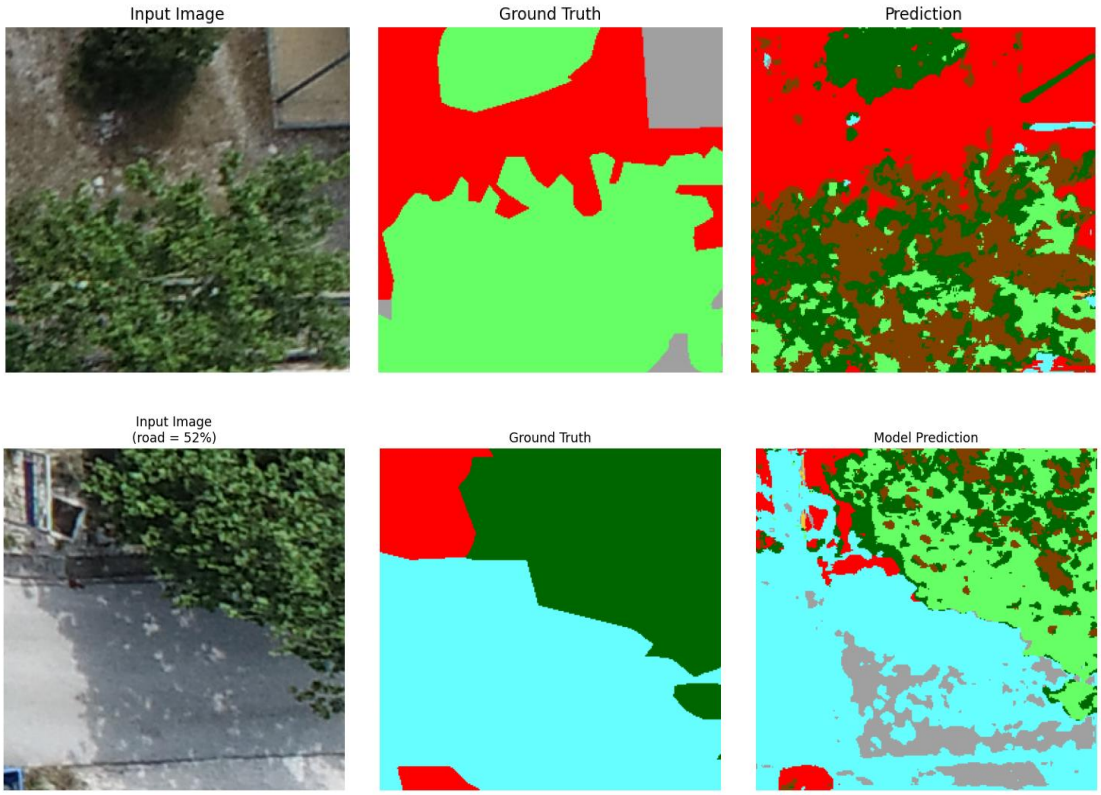

Σχήμα 26: Παραδείγματα εξόδου δικτύου.

Η τελική έξοδος του πλέον εκπαιδευμένου δικτύου όταν χρησιμοποιείται για πρόβλεψη φαίνεται στο Σχήμα 26. Αριστερά η εικόνα εισόδου 256,256 μεγέθους στη μέση η ετικετοποιημένη και δεξιά η πρόβλεψη/έξοδος του δικτύου.

Στο Σχήμα 27 παρουσιάζεται η τελική έξοδος του μοντέλου μετά την επανασυρραφή (stitching) των patches σε διάταξη 12×12, δημιουργώντας μία πλήρους ανάλυσης μάσκα συνολικού μεγέθους ίδιας με την αρχική εικόνα εισόδου. Διακρίνονται καθαρά οι γραμμές σύρραψης χωρίς εμφανή seam artifacts, ενώ οι βασικές κλάσεις αναπαρίστανται ορθά. Παρατηρούνται ωστόσο μικρές αβεβαιότητες στα όρια κλάσεων, ειδικά μεταξύ δρόμου και κτιρίων, υποδεικνύοντας περιθώρια βελτίωσης στη μετα-επεξεργασία των ακμών. Συνολικά, η συρραφή patches επιτυγχάνει ένα συνεκτικό segmentation, έτοιμο για περαιτέρω στάδια παραγωγής χάρτη επικινδυνότητας.

Σχήμα 27: Αποτέλεσμα συρραφής εξόδων δικτύου.

Στην προσπάθεια βελτίωσης της χωρικής ομοιογένειας των προβλέψεων, εφαρμόστηκε φίλτρο μεσαίου (median) με παράθυρο 41×41 pixels πάνω στην αρχική, «καθ' εαυτή» συρραφή (raw stitched prediction).

Το φίλτρο μεσαίου είναι μια εξαιρετικά απλή, μη γραμμική τεχνική επεξεργασίας εικόνας. Ένα παράθυρο διαστάσεων k×k (στην συγκεκριμένη περίπτωση 41x41) «ολίσθαίνει» πάνω στην εικόνα, και σε κάθε θέση συλλέγονται οι τιμές των pixels εντός του παραθύρου. Αυτές ταξινομούνται σε αύξουσα σειρά και επιλέγεται η κεντρική (μεσαία) τιμή, η οποία αντικαθιστά το αρχικό pixel. Με αυτόν τον τρόπο κάθε νέο pixel προκύπτει από τη μεσαία τιμή των γειτονικών του, χωρίς υπολογισμούς μέσου όρου ή βαρών.

Όπως μπορούμε να δούμε στο Σχήμα 28, η μετα-επεξεργασία εξαλείφει πολλές μικρές, σποραδικές προβλέψεις («salt-and-pepper noise»), ενισχύοντας τη συνέχεια των περιοχών, για παράδειγμα, τα μεγάλα ψηφία εδάφους αποκτούν ευθείες, αδιάσπαστες επιφάνειες, ενώ τα όρια ανάμεσα σε δρόμο και θάμνους γίνονται πιο ευκρινή.

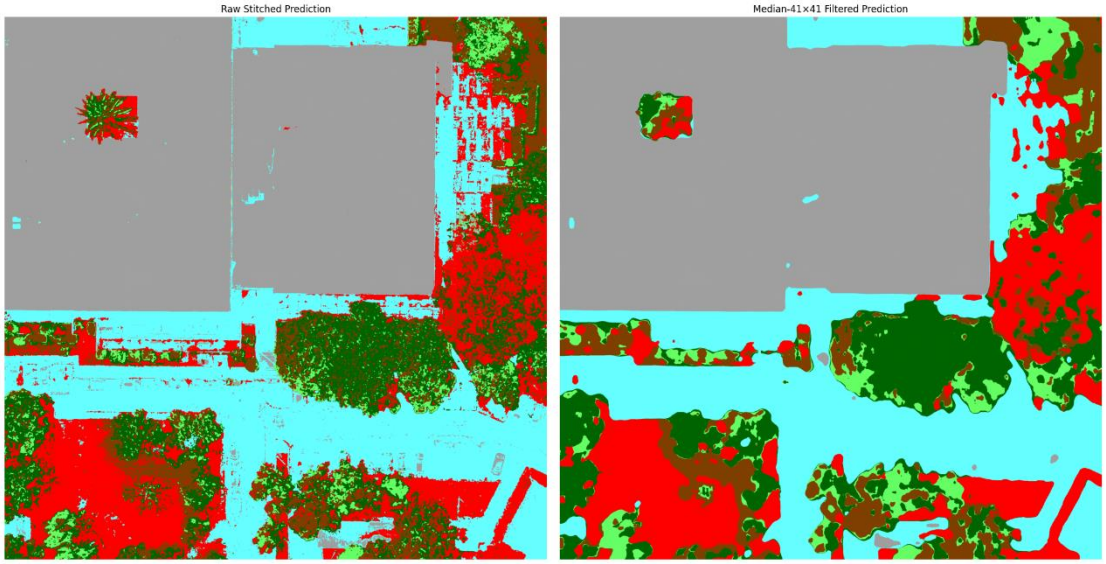

Σχήμα 28: Αποτέλεσμα εφαρμογής φίλτρου μέσου.

Η επίδραση του median φίλτρου στην ακρίβεια εντοπισμού των αντικειμένων απεικονίζεται αναλυτικά στη Γραφική Παράσταση 1 (βλ. Σχήμα 29), όπου παρουσιάζονται οι τιμές του Intersection over Union (IoU) για κάθε κλάση, πριν και μετά την εφαρμογή ενός χωρικού median φίλτρου 41×41 επί της εξόδου του μοντέλου.

Το IoU αποτελεί κρίσιμο δείκτη αξιολόγησης για την επικάλυψη μεταξύ των προβλεπόμενων και πραγματικών ετικετών, και άρα σχετίζεται άμεσα με την ποιότητα της χωρικής πληροφορίας.

Όπως φαίνεται, η εφαρμογή του φίλτρου είχε θετική επίδραση στις περισσότερες κλάσεις, βελτιώνοντας την καθαρότητα των προβλέψεων και περιορίζοντας τον «θόρυβο» στα όρια των αντικειμένων. Πιο συγκεκριμένα:

- Η κλάση ground παρουσίασε αύξηση του IoU από 0.379 σε 0.413, γεγονός που υποδεικνύει καλύτερη ενοποίηση των επιφανειών εδάφους.
- Οι θάμνοι (bush), που αποτελούν κλάση με σχετικά μικρή παρουσία, σημείωσαν επίσης μικρή αλλά σαφή βελτίωση (από 0.155 σε 0.183).
- Η κλάση mid tree ανέβηκε από 0.159 σε 0.228, παρουσιάζοντας την υψηλότερη σχετική βελτίωση, γεγονός που ενισχύει την υπόθεση ότι η φιλτραρισμένη έξοδος μειώνει την κατακερματισμένη πρόβλεψη στις ημι-συνεχείς δενδρώδεις περιοχές.
- Τα μεγάλα δέντρα (big tree), παρότι είχαν ήδη ικανοποιητικό σκορ (0.404), ενισχύθηκαν περαιτέρω σε 0.435.
- Η κλάση road παρουσίασε επίσης αξιοσημείωτη βελτίωση (από 0.780 σε 0.814), γεγονός που είναι κρίσιμο σε εφαρμογές χαρτογράφησης.

- Οι κατασκευές (building), με πολύ υψηλές τιμές IoU εξ αρχής, βελτιώθηκαν ελαφρώς από 0.937 σε 0.949, επιβεβαιώνοντας τη σταθερότητα της πρόβλεψης σε περιοχές με έντονες γεωμετρικές δομές.
- Τέλος, η κλάση electrical διατηρεί μηδενική τιμή, γεγονός που αποδίδεται γενικά στην εξαιρετικά μικρή παρουσία της στο σύνολο δεδομένων και ειδικά στην ολοκληρωτική απουσία της από τη συγκεκριμένη εικόνα (θα παρουσιαστεί σε μετέπειτα παράδειγμα). Συμπερασματικά οποιοδήποτε φιλτράρισμα δεν επηρεάζει την κλάση αυτή.

Συνολικά, τα αποτελέσματα καταδεικνύουν ότι ακόμη και ένα απλό φίλτρο χωρικής μεσαίας τιμής (median filter) μπορεί να προσφέρει σημαντικές ποιοτικές βελτιώσεις στις εξαγόμενες μάσκες, ιδιαίτερα για ανομοιογενείς ή θορυβώδεις κλάσεις, χωρίς να επηρεάζει αρνητικά τις υψηλά προβλέψιμες κατηγορίες. Αυτό το βήμα προσφέρει μικρό υπολογιστικό κόστος, αλλά σημαντικό όφελος για τη μετα-επεξεργασία εξόδων σε συστήματα υπολογιστικής όρασης.

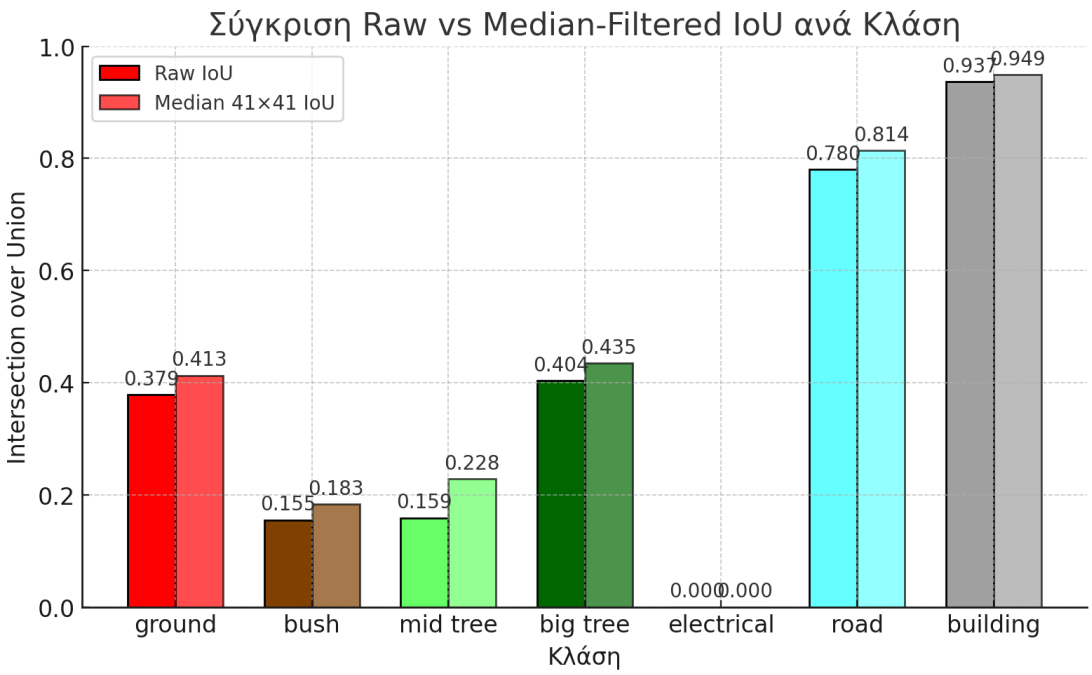

Γραφική Παράσταση 1

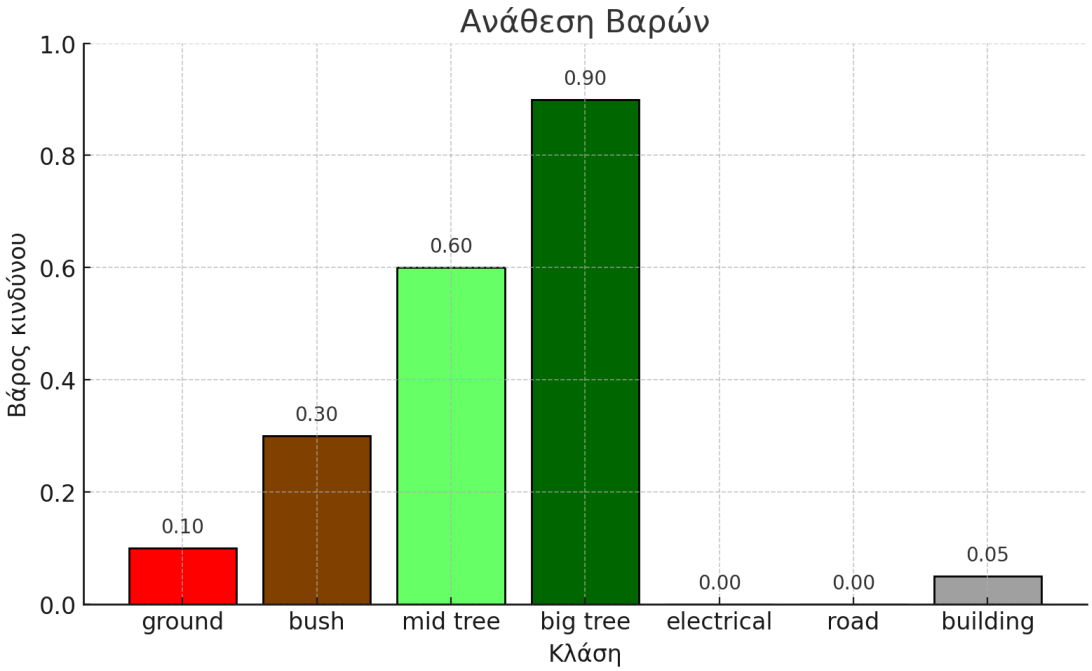

Γραφική Παράσταση 2

Σχήμα 29: Παράδειγμα βελτίωσης μετρικής IoU με εφαρμογή φίλτρου και ανάθεση Βαρών με μορφή γραφικής παράστασης.

Στη συνέχεια, κάθε προβλεφθείσα κλάση ετικέτας απέκτησε τον αντίστοιχο δείκτη κινδύνου (βάρος) όπως φαίνεται στο Γράφημα «Ανάθεση Βαρών» (Γραφική Παράσταση 2). Οι κλάσεις μεσαίας και υψηλής επικινδυνότητας (mid tree, big tree) έλαβαν υψηλότερες τιμές (0.60 και 0.90 αντίστοιχα), ενώ οι κλάσεις road και electrical χαρακτηρίστηκαν ουδέτερες (βάρος 0.00). Αυτή η διακριτή απόδοση βαρών επιτρέπει στη συνέχεια να ζωντανεύει η ένταση κινδύνου σε πραγματικό χώρο, με σαφή διαβάθμιση ανά pixel.

Κατόπιν, εφαρμόστηκε ένα φίλτρο εξομάλυνσης (median) με παράθυρο 9×9 pixels πάνω στον αρχικό «raw» χάρτη κινδύνου για την εξάλειψη μικρών σποραδικών ανωμαλιών και τη βελτίωση της οπτικής συνοχής (δες Σχήμα 30). Στην “Raw Danger Map” (πάνω δεξιά) διακρίνονται έντονες, μικροσκοπικές κηλίδες υψηλού κινδύνου διάσπαρτες σε επιφάνειες θάμνων και δέντρων, ενώ στον “Smoothed Danger Map” (κάτω αριστερά) οι περιοχές αυτές εμφανίζονται πλέον ως ενιαίες ζώνες με πιο ομαλές μεταβάσεις. Τέλος, στο “Overlay” (κάτω δεξιά) το χρωματισμένο επίπεδο κινδύνου αποτυπώνεται επάνω στην αρχική UAV εικόνα, αναδεικνύοντας σαφώς τις πιο επικίνδυνες ζώνες (ζεστοί τόνοι) σε σχέση με το περιβάλλον. Η οπτική αυτή απεικόνιση διευκολύνει τη γρήγορη κατανόηση του χάρτη κινδύνου και την υποστήριξη αποφάσεων σε πραγματικό χρόνο.

Παρατηρείται εύκολα, ότι στις περιοχές με πεύκα ή ευκάλυπτους το επίπεδο επικινδυνότητας φαίνεται πράγματι υψηλότερο, λίγες είναι οι περιοχές που υπάρχει σύγχυση του συστήματος και προβλήματα στην πρόβλεψη.

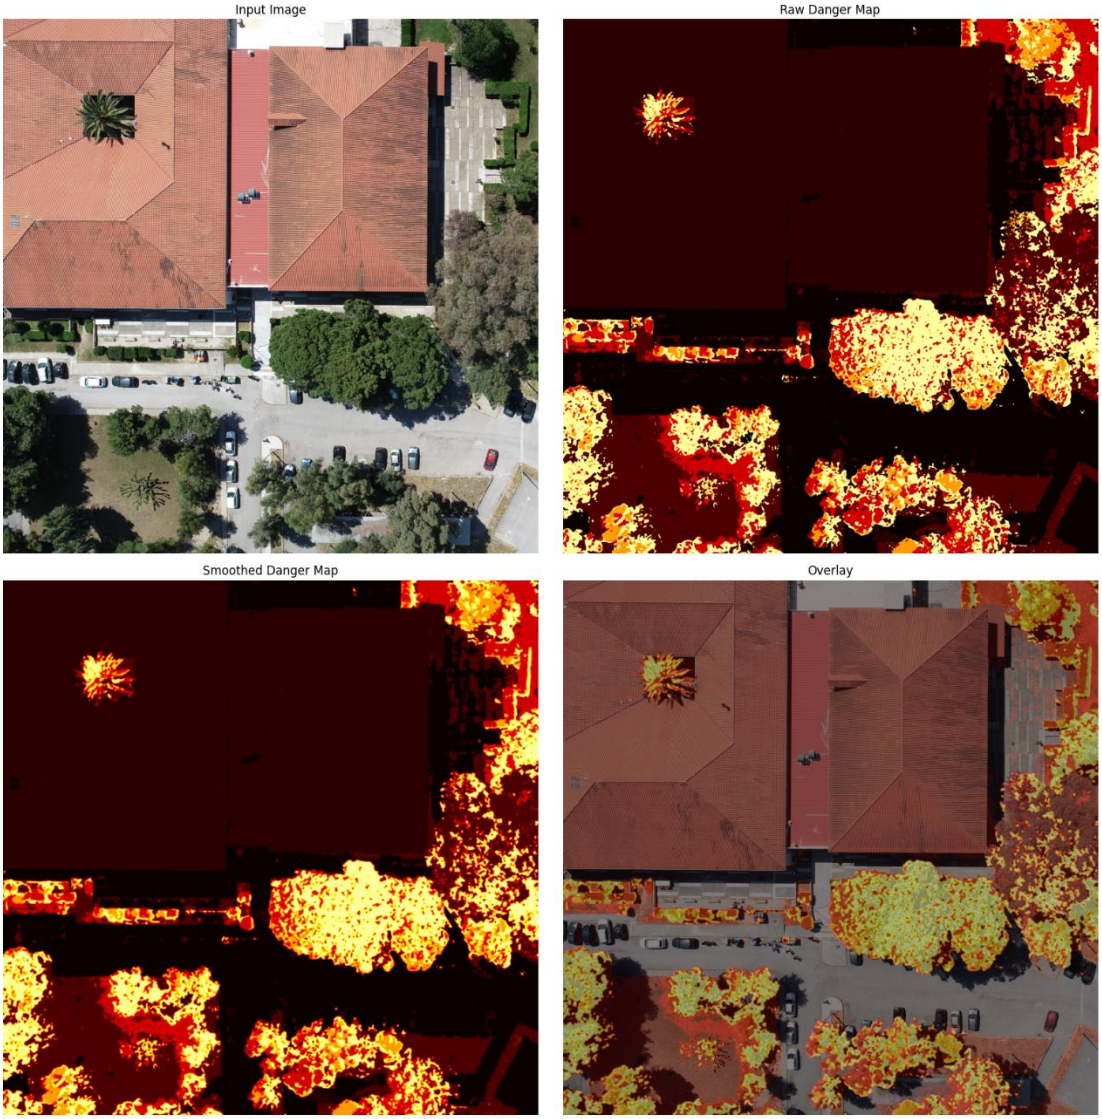

Σχήμα 30: Αποτέλεσμα τελικού χάρτη κινδύνου.

Τέλος, στο Σχήμα 31 και Σχήμα 32 ακολουθεί για άλλη μια φορά η ίδια διαδικασία μόνο που σε αυτή τη περίπτωση εξετάζεται και η εφαρμογή του εντοπισμού δικτυακού εξοπλισμού υψηλής τάσης, συγκεκριμένα καλώδια.

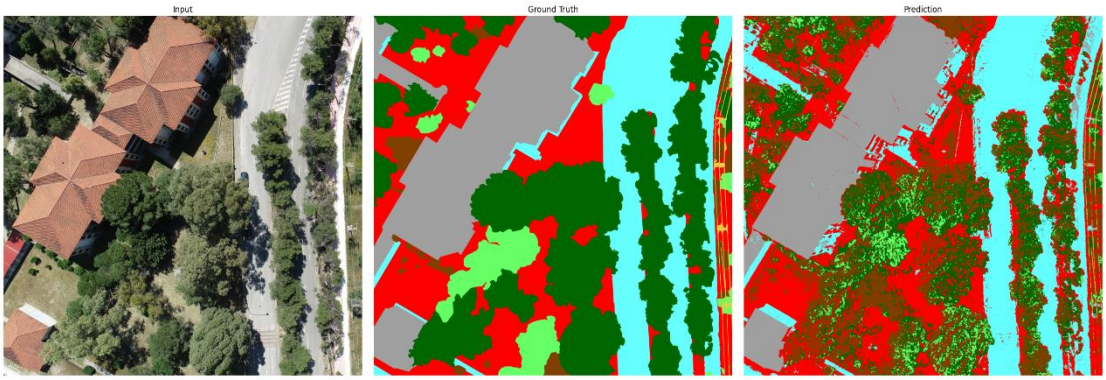

Σχήμα 31: Ένα ακόμη παράδειγμα.

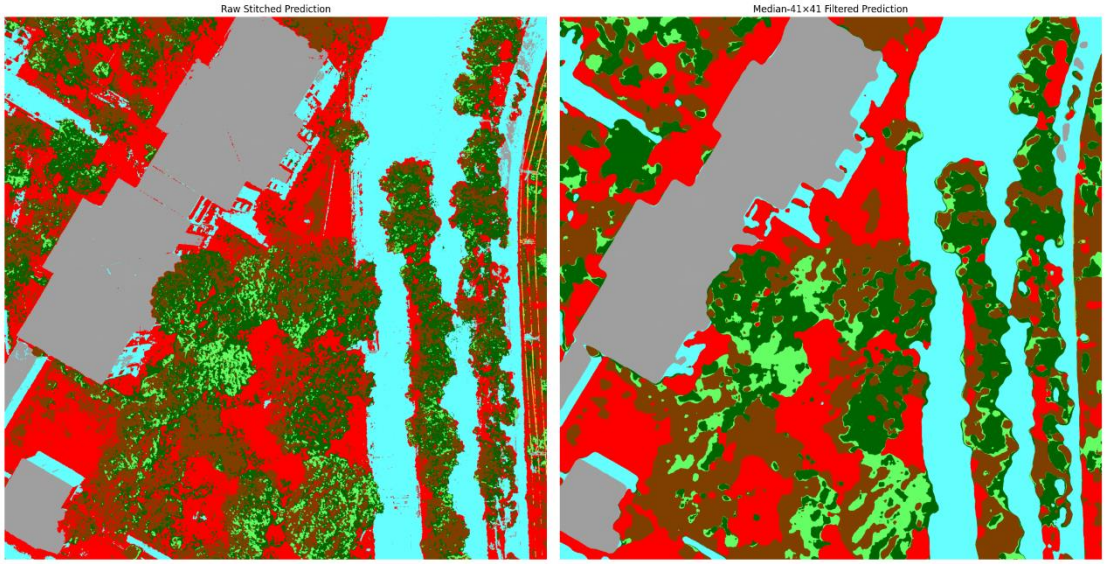

Σχήμα 32: Παράδειγμα με την εφαρμογή φίλτρου.

Στη Γραφική Παράσταση 1 (δες Σχήμα 33) παρουσιάζονται εκ νέου οι τιμές της μετρικής IoU, όπου παρατηρείται σημαντική αύξηση για όλες τις κλάσεις, με μοναδική εξαίρεση την electrical. Η απουσία βελτίωσης σε αυτή την κατηγορία οφείλεται στο γεγονός ότι τα αντικείμενα της, δηλαδή τα ηλεκτρικά καλώδια, έχουν πολύ μικρό πάχος και λεπτές γεωμετρικές δομές. Ως αποτέλεσμα, το χωρικό median φίλτρο δεν καταφέρνει να τα διατηρήσει, καθώς τα θεωρεί μεμονωμένα ή ασυνεχή pixel και τα αντικαθιστά με τις τιμές των γειτονικών περιοχών.

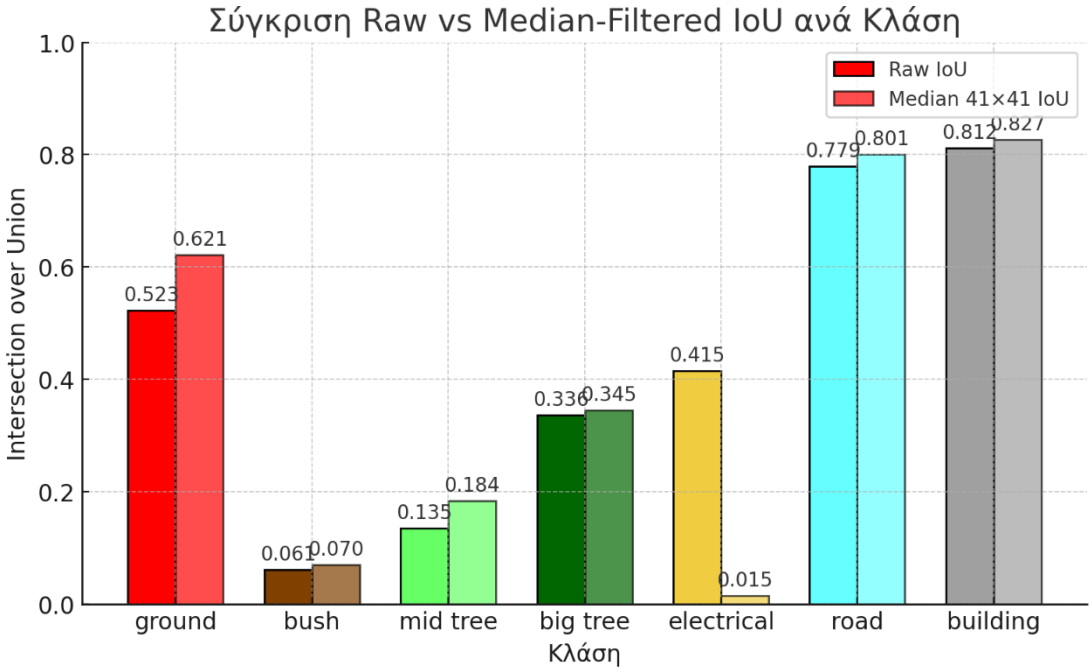

Γραφική Παράσταση 1

Σχήμα 33: IoU σε σύγκριση με τη μεταεπεξεργασία της εικόνας.

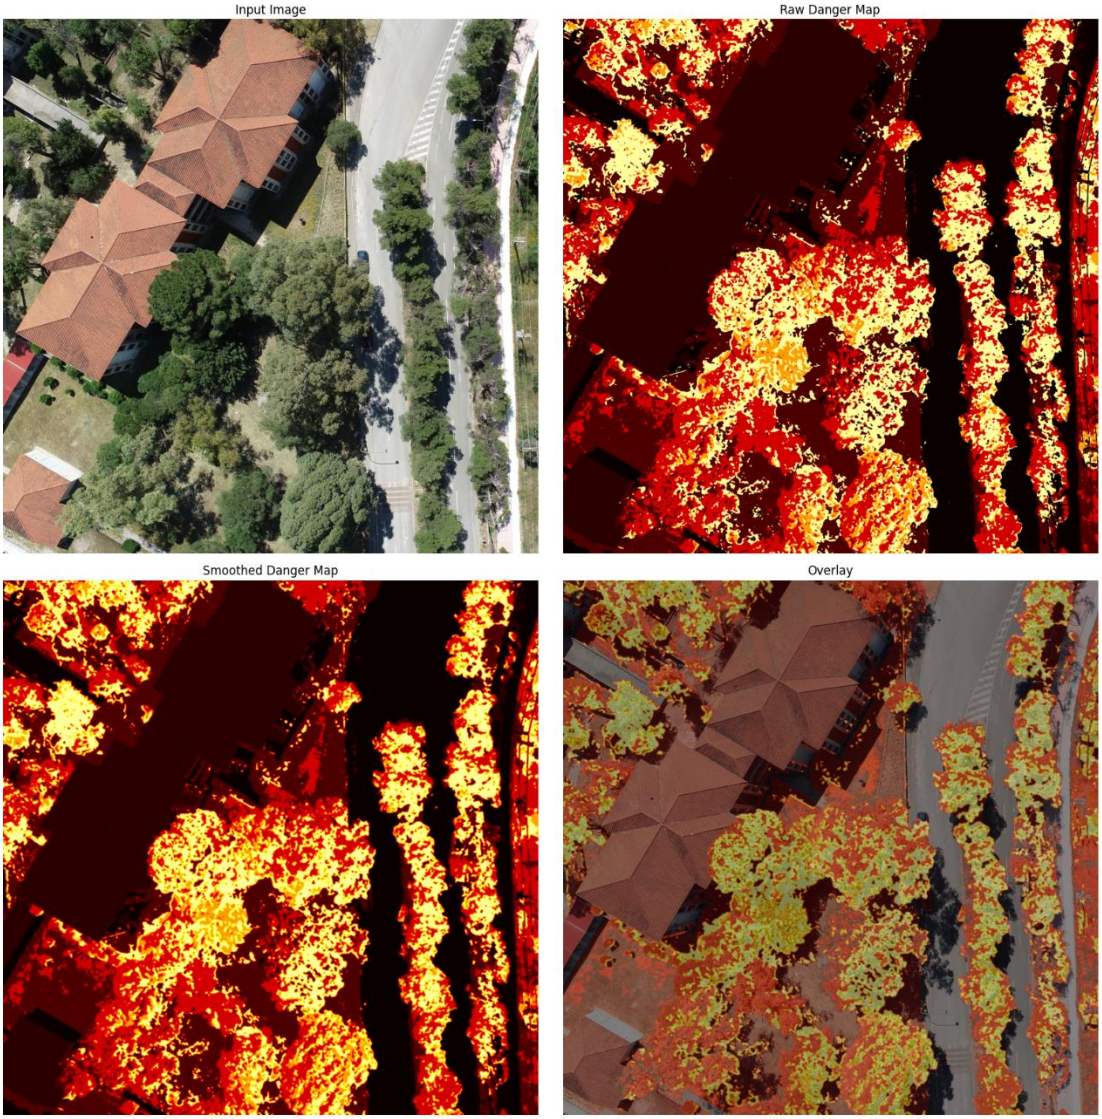

Σχήμα 34: Τελικός χάρτης κινδύνου.

Γυρνώντας μερικά βήματα πίσω στη διαδικασία ανάλυσης (δες Σχήμα 31), εφαρμόζεται ένας μετασχηματισμός στην τελική εικόνα κατηγοριοποίησης, κατά τον οποίο όλα τα pixels εκτός από εκείνα της κλάσης *electrical* μετατρέπονται σε μαύρα. Με αυτόν τον τρόπο δημιουργείται μια δυαδική μάσκα που αναδεικνύει αποκλειστικά τις περιοχές όπου το σύστημα εντόπισε την εν λόγω κλάση. Το αποτέλεσμα αποτυπώνεται στο Σχήμα 35, όπου οι περιοχές της κλάσης *electrical* απεικονίζονται με κίτρινη διαγράμμιση πάνω σε μαύρο φόντο.

Η δημιουργία αυτής της μάσκας είναι εξαιρετικά χρήσιμη σε εφαρμογές χωρικής χαρτογράφησης επικινδυνότητας, όπου η συγκατοίκηση ηλεκτρικών καλωδίων με δέντρα αποτελεί κρίσιμο παράγοντα για πρόληψη πυρκαγιών ή βλαβών στο δίκτυο. Ειδικότερα, η οπτική απομόνωση της κλάσης *electrical*, μέσω του διαχωρισμού της από το υπόλοιπο περιβάλλον, επιτρέπει την ακριβή εντόπιση των καλωδίων και την αξιολόγηση του αν βρίσκονται σε άμεση εγγύτητα με βλάστηση, όπως μεγάλα ή μεσαία

δέντρα, τα οποία μπορεί να πλήξουν την ακεραιότητα των γραμμών όταν υπάρχει έντονος άνεμος, πτώση κλαδιών ή παρατεταμένη επαφή.

Μέσω αυτής της προσέγγισης, είναι εφικτό να δημιουργηθεί ένας χάρτης προτεραιότητας καθαρισμού ή προληπτικής παρέμβασης, βοηθώντας τις αρμόδιες αρχές (π.χ. πυροσβεστική, ΔΕΔΔΗΕ, τοπική αυτοδιοίκηση) να εντοπίσουν με ακρίβεια τις πιο επικίνδυνες ζώνες. Συνεπώς, ακόμη και αν η κλάση *electrical* παρουσιάζει χαμηλές επιδόσεις σε κλασικές μετρικές (όπως το IoU), η στοχευμένη προβολή της σε συνδυασμό με γεωαναφορά καθιστά το σύστημα λειτουργικά χρήσιμο σε εφαρμογές έγκαιρης πρόληψης και αποκατάστασης.

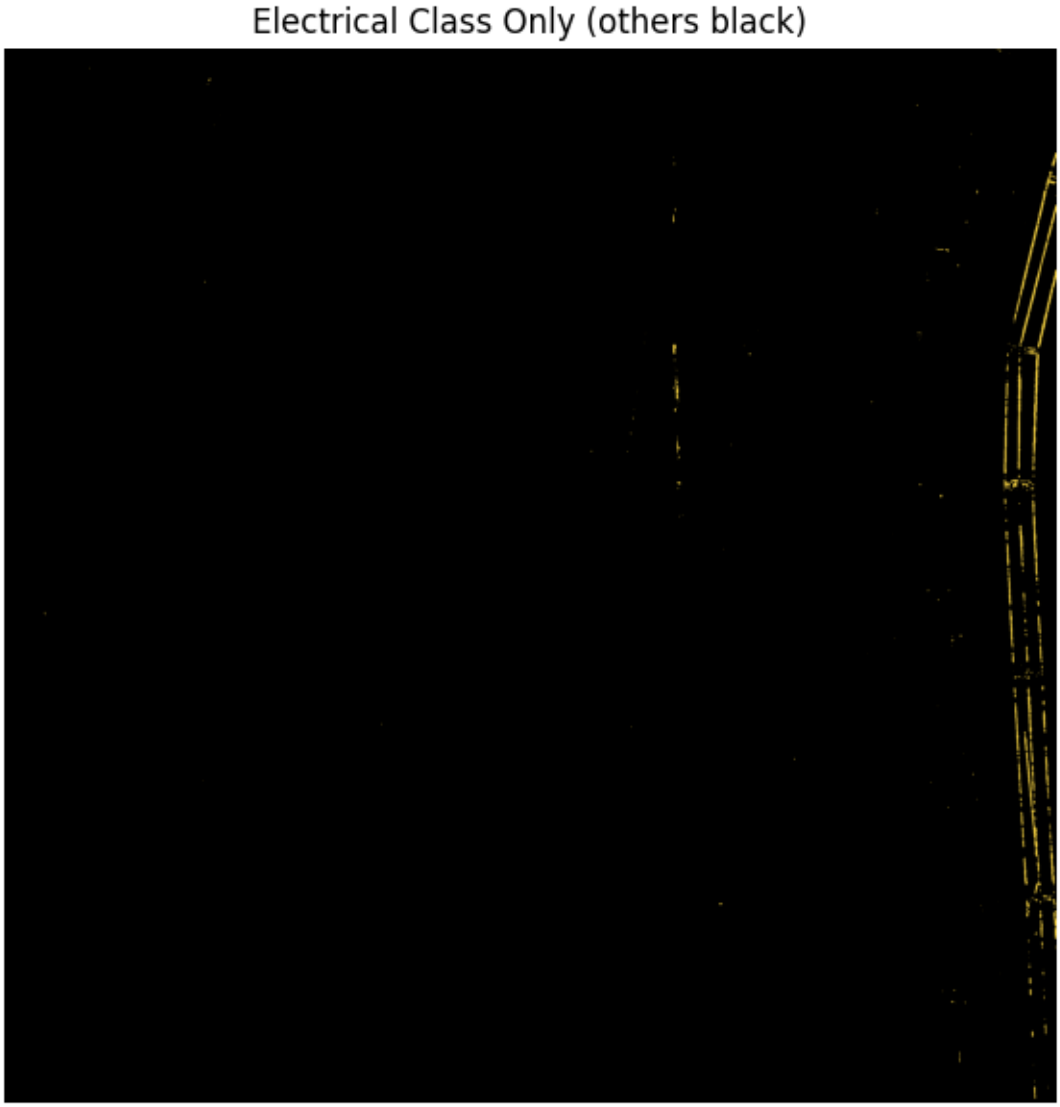

Σχήμα 35: Μάσκα που έχει διατηρήσει μόνο τα pixel της κλάσης electrical.

ΚΕΦΑΛΑΙΟ 6

Συμπεράσματα και Μελλοντική Εργασία

Στην παρούσα διπλωματική εργασία υλοποιήθηκε ένα πλήρως αυτοματοποιημένο pipeline για την παραγωγή χαρτών επικινδυνότητας δασικών πυρκαγιών αποκλειστικά από εικόνες UAV και δορυφορικών λήψεων, με χρήση τεχνικών σημασιολογικής κατάτμησης με χρήση νευρωνικών δικτίων αρχιτεκτονικής U-Net. Τα αποτελέσματα, αν και μετρίου επιπέδου (τελική ακρίβεια ~0.64, mean IoU ~0.30), αποδεικνύουν την εφικτότητα της μεθόδου και την ικανότητά της να διακρίνει τους βασικούς τύπους βιομάζας, υποδομών και δρόμων. Οι κύριοι παράγοντες που περιορίζουν την απόδοση είναι αυτοί που αναφέρονται στην Ενότητα 4.2.1 Περιορισμοί & Τελικό Pipeline. Εάν επιλυθούνε, και ιδιαίτερα το μέγεθος , η ποιότητα και η αντιπροσωπευτικότητα του σετ δεδομένων. Με στοχευμένες βελτιώσεις, όπως η διεύρυνση του dataset με επιπλέον πτήσεις drone, καθώς και περισσότερα είδη βλάστασης, η ποιοτικότερη ετικετοποίηση (περισσότερες και πληρέστερες μάσκες) και η εφαρμογή εξελιγμένων τεχνικών augmentation, αναμένεται σημαντική άνοδος των metrics.

Επιπλέον, ένας πολλά υποσχόμενος άξονας μελλοντικής έρευνας είναι η ενσωμάτωση των παραγόμενων χαρτών εικόνων με δυναμικούς δείκτες που βασίζονται σε μετεωρολογικά δεδομένα (θερμοκρασία, υγρασία, άνεμοι), καθώς και με προκαθορισμένα μοντέλα κινδύνου (π.χ. FWI, RiskMap). Ένας τέτοιος συνδυασμός θα παράγει περισσότερο ολιστικούς και προγνωστικούς χάρτες, υποστηρίζοντας την πρόληψη και την έγκαιρη απόκριση των πυροσβεστικών υπηρεσιών.

Τέλος, δεδομένης της ώριμης απόδοσης του μοντέλου κατάτμησης, το επόμενο βήμα είναι η πλήρης αυτοματοποίηση της διαδικασίας, από την πτήση του UAV και τη συλλογή εικόνων ως την παραγωγή τελικών χαρτών, με τη χρήση προγραμματισμένων αποστολών (mission planning) και pipelined διαχείρισης δεδομένων. Με αυτόν τον τρόπο, η πλατφόρμα θα μπορεί να λειτουργεί σε near-real-time περιβάλλοντα πεδίου, προσφέροντας έναν εύχρηστο και αξιόπιστο μηχανισμό διαχείρισης κινδύνου δασικών πυρκαγιών.

Βιβλιογραφία

[1] Z. Popović, S. Bojović, M. Marković, και A. Cerdà, “Tree species flammability based on plant traits: A synthesis,” Science of the Total Environment, vol. 800, p. 149625, 2021.

[2] G. Maria, E. Baccaglini, D. Brevi, M. Gavelli, και R. Scopigno, “A drone-based image processing system for car detection in a smart transport infrastructure,” in Proc. 18th Mediterranean Electrotechnical Conf. (MELECON), Limassol, Cyprus, 18–20 Apr. 2016.

[3] M. A. Finney, “FARSITE: Fire Area Simulator—model development and evaluation,” Res. Pap. RMRS-RP-4, USDA For. Serv., Rocky Mountain Res. Station, Ogden, UT, Mar. 1998.

[4] J. H. Scott και R. E. Burgan, “Standard fire behavior fuel models: a comprehensive set for use with Rothermel’s surface fire spread model,” Gen. Tech. Rep. RMRS-GTR-153, USDA For. Serv., Rocky Mountain Res. Station, Fort Collins, CO, Jun. 2005.

[5] H. E. Anderson, A photo guide to the 13 National Forest fuel models, Gen. Tech. Rep. INT-122, USDA For. Serv., Intermountain For. and Range Exp. Station, Ogden, UT, Apr. 1982.

[6] P. L. Andrews, “Current status and future needs of the BehavePlus fire modeling system,” Int. J. Wildland Fire, vol. 33, 2014.

[7] F. A. Albini, “Estimating wildfire behavior and effects,” Gen. Tech. Rep. INT-30, USDA For. Serv., Intermountain Res. Station, Ogden, UT, 1976.

[8] R. C. Rothermel, “A mathematical model for predicting fire spread in wildland fuels,” Res. Pap. INT-115, USDA For. Serv., Intermountain Forest and Range Exp. Station, Ogden, UT, 1972.

[9] R. C. Rothermel, “How to predict the spread and intensity of forest and range fires,” Gen. Tech. Rep. INT-143, USDA For. Serv., Intermountain Forest and Range Exp. Station, Ogden, UT, 1983.

[10] C. E. Van Wagner, “Conditions for the start and spread of crown fire,” Can. J. For. Res., vol. 7, pp. 23–34, 1977.

[11] T. L. Clark, M. A. Jenkins, J. L. Coen, και D. R. Packham, “A coupled atmosphere–fire model: convective feedback on fireline dynamics,” J. Appl. Meteor., vol. 35, no. 6, pp. 875–901, 1996.

[12] R. D. Ottmar και R. E. Vihnanek, Stereo photo series for quantifying natural fuels, Vols. I–VIa, PMS 830–838, Nat. Wildfire Coordinating Grp., Boise, ID, 1998–2003.

[13] C. S. Wright, R. D. Ottmar, και R. E. Vihnanek, Stereo photo series for quantifying natural fuels: Grassland, shrubland, woodland, and forest types in Hawaii, Gen. Tech. Rep. PNW-GTR-545, USDA For. Serv., Pacific Northwest Res. Station, Portland, OR, 2002.

[14] M. G. Bianchi και N. Defossé, “Fire dynamics in shrublands: a study of morphological traits and ignition,” Int. J. Wildland Fire, vol. 26, no. 8, pp. 725–734, 2017.

[15] V. Mola et al., “Interspecific variation in leaf-litter bed flammability: implications for ecosystem management,” Plant Ecol., vol. 215, pp. 757–766, 2014.

[16] X. Dimitrakopoulos και C. Papaioannou, “Flammability assessment of Mediterranean forest fuels,” Fire Safety J., vol. 36, pp. 171–183, 2001.

[17] T. Moranduzzo, F. Melgani, και A. Daamouche, “An object detection technique for very high resolution remote sensing images,” in 8th Int. Workshop on Systems, Signal Processing and Applications, May 2013, pp. 79–83.

[18] T. Viola και M. Jones, “Robust Real Time Object Detection,” in Proc. IEEE ICCV Workshop on Statistical and Computational Theories of Vision, July 2001.

[19] S. Liao et al., “Learning Multi-scale Block Local Binary Patterns for Face Recognition,” in Int. Conf. Biometrics (ICB), 2007, pp. 828–837.

[20] Hellenic Fire Service, “Annual Report on Forest Fires in Greece 2023,” Hellenic Fire Service, Athens, 2024.

[21] Panhellenic Wildlife Federation, “Impact of 2023 Wildfires on Fauna in Greece,” PWF Report, 2024.

[22] Institute for Soil Erosion and Water Management, “Post-fire Soil Erosion and Water Resource Impacts in Greece,” IS Erosion, 2024.

[23] Greek National Meteorological Service, “Storm Daniel 2023 Flood Report,” GNMS, 2023.

[24] NASA, “MODIS Instrument User’s Guide,” NASA Earth Observing System, 2022.

[25] NOAA, “VIIRS Product Guide,” National Oceanic and Atmospheric Administration, 2022.

[26] Hellenic Fire Service, “After-Action Review: Schinos Fire Incident 2023,” Hellenic Fire Service, 2024.

[27] Food and Agriculture Organization, “Global Forest Resources Assessment 2020 – Country Report: Greece,” FAO, Rome, 2020.

[28] National Forest Inventory of Greece, “Forest Cover Statistics 1990–2022,” Ministry of Environment and Energy, Athens, 2023.

[29] European Forest Institute, “Forest Zonation and Species Distribution in Mediterranean Europe,” EFI Technical Report 2019/05, 2019.

[30] European Space Agency, “Sentinel-2 User Handbook,” ESA, Noordwijk, 2015.

[31] NASA LP DAAC, “MODIS Land User’s Guide,” NASA, 2018.

[32] J. Long, E. Shelhamer, και T. Darrell, “Fully Convolutional Networks for Semantic Segmentation,” in Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR), 2015, pp. 3431–3440.

[33] O. Ronneberger, P. Fischer, και T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2015, pp. 234–241.

Παράρτημα

Παρακάτω παραθέτω έναν σύνδεσμο που ανακατευθύνει στο αρχείο με τα κομμάτια κώδικα σε κάθε εφαρμογή που προαναφέρονται.

https://github.com/argi4s/Thesis